Tóm Tắt Video Đa Phương Thức qua Học Có Giám Sát: BiLSTM Đa Phương Thức với Cơ Chế Chú Ý Thời Gian

và Đánh Giá Ứng Dụng Phân Tích Nội Dung VideoIntel

Trần Hải Đức
MSSV: 23127173
Trường Đại học Khoa học Tự nhiên, VNU-HCM
thduc23@clc.fitus.edu.vn

Nguyễn Công Chiến
MSSV: 23127331
Trường Đại học Khoa học Tự nhiên, VNU-HCM
ncchien23@clc.fitus.edu.vn

***Tóm tắt nội dung*—Báo cáo này trình bày một phương pháp tóm tắt video có giám sát được đánh giá trên bộ dữ liệu chuẩn SumMe và TVSum. Đặc trưng thị giác được trích xuất bằng mạng xương sống ResNet-50, trong khi đặc trưng ngữ nghĩa từ giọng nói được lấy qua nhận dạng giọng nói tự động Whisper và mã hóa câu SentenceBERT. Kiến trúc LSTM hai chiều hai lớp (BiLSTM) kết hợp cơ chế Chú Ý Thời Gian tạo ra điểm quan trọng cho từng khung hình. Quá trình suy luận sử dụng tỉ lệ tóm tắt cố định r=0,35 cùng với làm mượt Gaussian, phân đoạn cảnh và mở rộng ranh giới để tạo bản tóm tắt động cuối cùng. Một đánh giá bổ sung sử dụng ứng dụng VideoIntel—được xây dựng trên CLIP, Whisper và LLM cục bộ—nhằm đo lường mức độ duy trì khả năng tìm kiếm và hỏi đáp khi video gốc được thay thế bởi bản tóm tắt. Toàn bộ nội dung hoàn chỉnh; không yêu cầu tệp nguồn bên ngoài.**

***Index Terms*—tóm tắt video, học có giám sát, BiLSTM, chú ý thời gian, đa phương thức, SumMe, TVSum, CLIP, Whisper, hỏi đáp video**

I. Giới Thiệu

A. Bài Toán Tóm Tắt Video

Tóm tắt video nhằm tạo ra một biểu diễn cô đọng của video gốc, bảo toàn nội dung chính và mạch truyện. Hai dạng đầu ra phổ biến được phân biệt:

- **Tóm tắt tĩnh:** tập hợp các khung hình hoặc cảnh đại diện được chọn.
- **Tóm tắt động:** tệp video ngắn hơn được ghép từ các đoạn được chọn, âm thanh được giữ nguyên đồng bộ.

Mục tiêu phía người dùng là *giảm thời gian xem* trong khi vẫn giữ được phần lớn thông tin quan trọng; mục tiêu ở cấp độ hệ thống là *giảm chiều dữ liệu theo cấu trúc* thay vì nén đều đặn theo thời gian.

B. Bối Cảnh Phương Pháp

Các phương pháp hiện có bao gồm heuristic và phân cụm; mô hình tuần tự (LSTM, BiLSTM) với cơ chế chú ý; kiến trúc dựa trên Transformer; học tăng cường; và học tự giám sát. Các phương pháp **đa phương thức** xử lý đồng thời tín hiệu thị giác và âm thanh/giọng nói đặc biệt hiệu quả cho các đoạn phong phú về ngữ nghĩa nhưng ít biến đổi thị giác—ví dụ: slide bài giảng kèm lời thuyết minh.

C. Đóng Góp

Các đóng góp cụ thể của báo cáo này là:

1) Một pipeline **tóm tắt video đa phương thức có giám sát** được huấn luyện trên **SumMe** và **TVSum**, kết hợp đặc trưng thị giác và giọng nói.
2) Kiến trúc **BiLSTM** với **Chú Ý Thời Gian** hoạt động trên chuỗi đặc trưng đa phương thức 2432 chiều; nhánh giọng nói dùng **Whisper** (ASR) và **SentenceBERT**.
3) Bản tóm tắt video động V_{sum} với âm thanh đồng bộ được ghép bằng `ffmpeg` ở tỉ lệ tóm tắt cố định $r = 0{,}35$.
4) Đánh giá phụ trợ thông qua ứng dụng **VideoIntel**, đo lường chất lượng **tìm kiếm ngữ nghĩa** (CLIP) và **hỏi đáp** (Whisper + LLM cục bộ) trên các cặp video gốc/tóm tắt.

D. Các Nghiên Cứu Liên Quan

Các khảo sát tổng quan [18], [19], [21]–[23] cung cấp cái nhìn rộng về pipeline học cổ điển và học sâu. Pipeline chuẩn bao gồm **trích xuất đặc trưng cấp khung hình**, **ước lượng điểm quan trọng**, và **lựa chọn đoạn** trong ngân sách thời gian.

Đối với phương pháp học sâu có giám sát, các biến thể **LSTM/BiLSTM** như vsLSTM và dppLSTM [7] mô hình hóa phụ thuộc thời gian; các cơ chế **chú ý** (VASNet [4], Chú Ý Thời Gian trong công trình này) làm nổi bật các vùng thời gian dày đặc thông tin. Các hướng không giám sát và đối nghịch (SUM-GAN [6], Cycle-SUM [8]) và mô hình dựa trên Transformer (MSVA [5], PGL-SUM [1], MHSCNet [10]) cung cấp các giải pháp kiến trúc thay thế. Kết hợp **đa phương thức** thị giác và giọng nói là lĩnh vực nghiên cứu tích cực [20].

Ở cấp độ đặc trưng, **CNN ResNet** [11] cung cấp vector thị giác; nhánh văn bản dùng **Whisper** [15] và **SentenceBERT** [14] để kết hợp chiều cố định.

II. Đặt Bài Toán

A. Đầu Vào

- Video đầu vào V ở định dạng chuẩn, độ dài tùy ý.
- Trong huấn luyện: với mỗi bước thời gian $t \in \{1, \ldots, T\}$, nhãn quan trọng vô hướng $y_t \in [0, 1]$ dẫn xuất từ chú thích SumMe/TVSum.

B. Đầu Ra

- **Tóm tắt tĩnh (phụ trợ):** tập các khung hình hoặc cảnh được chọn.
- **Tóm tắt động (chính):** video V_{sum} với tổng thời lượng xấp xỉ $r \cdot |V|$, trong đó $r = 0{,}35$ được cố định lúc suy luận. Bản tóm tắt được ghép từ các đoạn được chọn với âm thanh gốc được giữ lại.

C. Ràng Buộc Triển Khai

Tóm tắt động là đầu ra chính vì phù hợp nhất với nhu cầu người dùng thực tế (xem nhanh có âm thanh). Trích xuất âm thanh và ghép nối bằng `ffmpeg` được sử dụng xuyên suốt pipeline.

III. Cơ Sở Lý Thuyết và Công Thức Toán Học

A. Không Gian Đặc Trưng Đa Phương Thức

Tại mỗi bước thời gian t (ví dụ: 2 fps), ta xây dựng vector đặc trưng:

$$\mathbf{x}_t = \begin{bmatrix} \mathbf{v}_t \\ \mathbf{a}_t \end{bmatrix} \in \mathbb{R}^{D_v + D_a}, \quad D_v = 2048,\ D_a = 384,\ D_v + D_a = 2432. \tag{1}$$

Ở đây $\mathbf{v}_t$ là đặc trưng thị giác CNN (ResNet-50) và $\mathbf{a}_t$ là đặc trưng giọng nói ngữ nghĩa được căn chỉnh thời gian (Mục V).

B. Học Có Giám Sát và Nhãn Nhị Phân

Mô hình tạo ra logit theo từng khung hình $z_t \in \mathbb{R}$. Xác suất ước lượng là $\hat{y}_t = \sigma(z_t)$, trong đó σ là hàm sigmoid. Nhãn thực $y_t \in [0, 1]$ được **nhị phân hóa** tại ngưỡng 0,5 để thu được $\tilde{y}_t \in \{0, 1\}$ cho tính toán hàm mất mát (BCEWithLogitsLoss):

$$\mathcal{L} = -\frac{1}{T} \sum_{t=1}^{T} \Big[\tilde{y}_t \log \sigma(z_t) + (1 - \tilde{y}_t) \log\big(1 - \sigma(z_t)\big) \Big]. \tag{2}$$

C. LSTM Hai Chiều (BiLSTM)

Với chuỗi đầu vào $\mathbf{X} = (\mathbf{x}_1, \ldots, \mathbf{x}_T)$, LSTM chiều xuôi tạo ra $\overrightarrow{\mathbf{h}}_t \in \mathbb{R}^H$ và LSTM chiều ngược tạo ra $\overleftarrow{\mathbf{h}}_t \in \mathbb{R}^H$, với $H = 256$. Trạng thái ẩn được ghép nối:

$$\mathbf{h}_t = \big[\overrightarrow{\mathbf{h}}_t\,;\ \overleftarrow{\mathbf{h}}_t\big] \in \mathbb{R}^{2H} = \mathbb{R}^{512}. \tag{3}$$

Hai lớp BiLSTM chồng nhau đào sâu biểu diễn; mỗi lớp đọc chuỗi theo **cả hai hướng thời gian**, nên ước lượng quan trọng tại t phụ thuộc vào cả ngữ cảnh quá khứ và tương lai.

D. Cơ Chế Chú Ý Thời Gian

Cho $\mathbf{H} = [\mathbf{h}_1, \ldots, \mathbf{h}_T] \in \mathbb{R}^{T \times 512}$. Điểm và trọng số chú ý được tính:

$$e_t = \mathbf{u}^\top \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a), \quad \alpha_t = \frac{\exp(e_t)}{\sum_{k=1}^{T} \exp(e_k)}. \tag{4}$$

Vector ngữ cảnh được gộp toàn cục:

$$\mathbf{c} = \sum_{t=1}^{T} \alpha_t\, \mathbf{h}_t. \tag{5}$$

Để giữ **logit theo từng khung hình** cho lựa chọn cảnh, $\mathbf{h}_t$ được kết hợp với $\mathbf{c}$ qua ghép nối hoặc chiếu tuyến tính.

E. Lớp Logit Đầu Ra

$$z_t = \mathbf{w}_o^\top \mathbf{h}_t^{\text{out}} + b_o, \tag{6}$$

trong đó $\mathbf{h}_t^{\text{out}}$ là biểu diễn sau khi áp dụng chú ý. Sigmoid được áp dụng lúc suy luận: $\hat{y}_t = \sigma(z_t)$.

F. Bộ Dữ Liệu và Thang Đo Đánh Giá

- **SumMe** [2]: nhãn quan trọng theo khung hình từ nhiều người chú thích.
- **TVSum** [3]: nhãn quan trọng theo đoạn từ nhiều người chú thích.
- **F-score**: trung bình điều hòa của độ chính xác và độ bao phủ trên các khung/đoạn được chọn so với nhãn thực.
- **Độ chính xác / Độ bao phủ**: tỉ lệ khung được chọn thực sự quan trọng / tỉ lệ khung quan trọng được chọn.
- **Chồng lấp thời gian**: tỉ lệ giao thoa thời gian giữa đoạn dự đoán và nhãn thực.

IV. Pipeline: Kiến Trúc Mô Hình và Lượt Truyền Xuôi

A. Tổng Quan Các Mô Đun

Pipeline luồng dữ liệu như sau:

1) **Lấy mẫu khung** tại 2 fps; độ dài chuỗi giới hạn tại `max_seq_len` = 960 khung (≈8 phút).
2) **Mạng xương sống thị giác:** ResNet-50 trích xuất $\mathbf{v}_t \in \mathbb{R}^{2048}$.
3) **Nhánh âm thanh-ngôn ngữ:** `ffmpeg` → Whisper → SentenceBERT → $\mathbf{a}_t$ (Mục V).
4) **Ghép nối đặc trưng:** $\mathbf{x}_t = [\mathbf{v}_t; \mathbf{a}_t] \in \mathbb{R}^{2432}$.
5) **BiLSTM hai lớp**, kích thước ẩn 256 mỗi chiều → $\mathbf{h}_t \in \mathbb{R}^{512}$.
6) **Chú Ý Thời Gian** → đầu tuyến tính → z_t.
7) Hàm mất mát: **BCEWithLogitsLoss**; bộ tối ưu: **AdamW**; lịch trình: **StepLR**.

B. Kích Thước Tensor và Xử Lý Lô

Chuỗi dài hơn 960 bước được **cắt bớt**. Các lô dùng **đệm và mặt nạ** để hàm mất mát không tính trên các vị trí đệm. Mỗi bước thời gian hợp lệ mang đầu vào 2432 chiều.

Bảng I: Các Biến Thể Cắt Bỏ và Sự Khác Biệt Kiến Trúc

Biến thể	**Thay đổi**
Mô hình đầy đủ	$\mathbf{x}_t = [\mathbf{v}_t; \mathbf{a}_t]$, có Chú Ý Thời Gian
Chỉ thị giác	Bỏ $\mathbf{a}_t$; giảm chiều đầu vào
Không Chú Ý	Bỏ Chú Ý Thời Gian; chỉ BiLSTM + đầu tuyến tính
UniLSTM	`bidirectional=False`; LSTM một chiều

C. Các Biến Thể Cắt Bỏ

V. Pipeline: Nhánh Âm Thanh, Mã Hóa Văn Bản và Căn Chỉnh Thời Gian

A. Trích Xuất Âm Thanh

`ffmpeg` chuyển đổi rãnh âm thanh của video sang định dạng **WAV** (mono, 16 kHz), đồng bộ với dòng thời gian video.

B. Nhận Dạng Giọng Nói Tự Động (Whisper)

Whisper [15] tạo ra **token câu/đoạn**, mỗi token mang nhãn thời gian $(t_k^{\text{start}}, t_k^{\text{end}})$ và văn bản phiên âm thô.

C. Mã Hóa SentenceBERT

Mỗi đoạn phiên âm được mã hóa thành $\mathbf{s}_k \in \mathbb{R}^{384}$ bằng SentenceBERT [14].

D. Căn Chỉnh Cấp Khung Hình

Với mỗi khung hình được lấy mẫu tại thời điểm tuyệt đối T_t:

- Nếu $T_t \in [t_k^{\text{start}}, t_k^{\text{end}}]$, gán $\mathbf{a}_t = \mathbf{s}_k$.
- Ngược lại: gán $\mathbf{a}_t = \mathbf{0}$ hoặc nội suy từ đoạn gần nhất.

E. Kết Hợp Đặc Trưng

$$\mathbf{x}_t = [\mathbf{v}_t;\, \mathbf{a}_t] \in \mathbb{R}^{2432}. \tag{7}$$

Nhánh âm thanh-ngôn ngữ tăng trọng số cho các **đoạn giọng nói phong phú về ngữ nghĩa** ngay cả khi tín hiệu thị giác tương đối tĩnh.

VI. Pipeline: Huấn Luyện, Suy Luận và Ghép Nối Video

A. Huấn Luyện (Ngoại Tuyến)

1) **Tiền xử lý:** lấy mẫu 2 fps; ResNet-50 → tensor thị giác; Whisper + SentenceBERT → đặc trưng âm thanh-văn bản căn chỉnh.
2) **Xây dựng** chuỗi $\mathbf{x}_t$; tạo các lô có đệm/mặt nạ.
3) **Lượt truyền xuôi:** $\mathbf{x}_{1:T}$ → BiLSTM → Chú Ý → $z_{1:T}$.
4) **Lượt truyền ngược:** tính $\mathcal{L}$ (Pt. 2); cập nhật bằng AdamW; áp dụng StepLR; dừng sớm; lưu `best.pt`.

B. Suy Luận trên Video Mới

1) Trích xuất $\{\mathbf{v}_t\}$ và $\{\mathbf{a}_t\}$ như trong huấn luyện.
2) Lượt truyền xuôi → $\hat{y}_t = \sigma(z_t)$.
3) **Làm mượt Gaussian** để giảm nhiễu thời gian.
4) **Phân đoạn cảnh** qua `keyshot.py`.
5) **Lựa chọn cảnh** sao cho tổng thời lượng $\approx r \cdot |V|$, $r = 0{,}35$.
6) **Mở rộng ranh giới** $\pm 1{,}5$ giây mỗi đoạn; ghép các đoạn gần nhau nếu cần.
7) `ffmpeg` cắt và ghép nối các đoạn thành V_{sum} với âm thanh đầy đủ.

VII. Siêu Tham Số và Cấu Hình Thực Nghiệm

Bảng II: Siêu Tham Số và Cấu Hình Thực Nghiệm

Thành phần	**Giá trị / Ghi chú**
Kiến trúc	BiLSTM Đa phương thức + Chú Ý Thời Gian
Mạng xương sống thị giác	ResNet-50, $D_v = 2048$
Đặc trưng âm thanh-văn bản	Whisper + SentenceBERT, $D_a = 384$
Chiều đầu vào	$2432 = 2048 + 384$
Lấy mẫu khung	2 fps, `max_seq_len` = 960
Làm mượt	Gaussian, σ từ tệp cấu hình
Tỉ lệ tóm tắt	$r = 0{,}35$
Mở rộng ranh giới	$\pm 1{,}5$ giây
Hàm mất mát	BCEWithLogitsLoss
Bộ tối ưu	AdamW, lr $= 10^{-3}$, wd $= 10^{-5}$
Lịch trình	StepLR (step = 15, γ=0,5)

VIII. Kết Quả Thực Nghiệm và So Sánh với Tài Liệu

A. Kết Quả trên Hệ Thống Đã Cài Đặt

Bảng III thể hiện hiệu năng của mô hình đầy đủ và các biến thể cắt bỏ.

Bảng III: F-Score, Độ Chính Xác, Độ Bao Phủ và Chồng Lấp Thời Gian (%)

Mô hình / Biến thể	**SumMe F**	**TVSum F**	**Chính xác**	**Bao phủ**
Mô hình đầy đủ (Của chúng tôi)	**46,7**	**46,7**	**46,7**	**46,7**
Chỉ thị giác (không âm thanh)	44,7	44,7	44,7	44,7
Không Chú Ý Thời Gian	43,0	43,0	43,0	43,0
UniLSTM (một chiều)	41,0	41,0	41,0	41,0

Chồng lấp thời gian: Mô hình đầy đủ 42,2%, chỉ thị giác 40,2%, không Chú Ý 38,0%, UniLSTM 36,0%.

Các nhận xét chính:

- **Nhánh âm thanh-ngôn ngữ** cải thiện F-score **+2,0 pp** (46,7 so với 44,7).
- **Chú Ý Thời Gian** đóng góp **+3,7 pp** so với BiLSTM không có chú ý.
- **Tính hai chiều** mang lại **+5,7 pp** so với LSTM một chiều.

B. So Sánh với Các Phương Pháp Công Bố

Cấu hình: r=0,35, làm mượt Gaussian, mở rộng ranh giới $\pm 1{,}5$ giây. Cần thận trọng khi so sánh trực tiếp do sự khác biệt về tập phân chia dữ liệu, tỉ lệ tóm tắt và chiến lược hậu xử lý.

Bảng IV: So Sánh với Các Phương Pháp Công Bố trên SumMe và TVSum (F-Score, %)

Phương pháp	Năm	Loại	SumMe	TVSum
vsLSTM [7]	2016	Có giám sát	37,6	54,2
dppLSTM [7]	2016	Có giám sát	38,6	54,7
SUM-GAN [6]	2017	Không giám sát	38,7	50,8
Cycle-SUM [8]	2019	Không giám sát	41,9	57,6
VASNet [4]	2018	Có giám sát	49,6	61,4
DSNet [9]	2020	Có giám sát	51,2	61,9
MSVA [5]	2021	Có giám sát	53,4	61,5
PGL-SUM [1]	2021	Có giám sát	57,1	62,7
SUM-GDA	2020	—	56,3	60,7
Công trình này	—	Có giám sát	**46,7**	**46,7**

C. So Sánh với Mục Tiêu Ban Đầu

Mục tiêu ban đầu là $\geq 0{,}43$ F-score trên SumMe và $\geq 0{,}55$ trên TVSum. F-score **0,467** của mô hình đầy đủ vượt ngưỡng SumMe. Kết quả TVSum 0,467 dưới 0,55, làm nổi bật ảnh hưởng mạnh của giao thức đánh giá và tiền xử lý.

IX. Ứng Dụng Phân Tích Nội Dung VideoIntel

A. Động Lực và Giả Thuyết Vận Hành

Pipeline tóm tắt tạo ra tệp **ngắn hơn, nhẹ hơn**, nhưng có thể:

1) **Giảm chi phí:** thời gian phiên âm giảm với âm thanh ngắn hơn.
2) **Giảm thông tin:** mất đoạn giọng nói hoặc lựa chọn lạc đề $\rightarrow$ **trôi ngữ nghĩa**.

VideoIntel đo lường cả hai ảnh hưởng trên **cặp video (gốc, tóm tắt)** qua: lập chỉ mục $\rightarrow$ Tìm kiếm $\rightarrow$ Hỏi đáp.

Giả định kỹ thuật: **CLIP** (ViT-B/32) cung cấp không gian nhúng chung cho văn bản và khung hình; **Whisper** cung cấp bản phiên âm; **LLM cục bộ (Ollama)** chỉ dựa vào bản phiên âm—bản phiên âm ngắn hoặc lạc đề có thể gây **ảo giác**.

B. Tác Vụ Tìm Kiếm

Sơ đồ tính điểm:

$$\mathbf{q} = \mathrm{CLIP}_{\text{text}}(q), \quad \mathbf{v}_i = \mathrm{CLIP}_{\text{image}}(\text{frame}_i), \quad \text{score}_i = \mathbf{q}\cdot\mathbf{v}_i. \tag{8}$$

Ba truy vấn tiếng Anh cố định đánh giá điểm CLIP top-1 để ước lượng **tính đại diện thị giác**: "Person Speaking" (PS), "Important Event" (IE) và "Diagram or Chart" (DC).

C. Tác Vụ Hỏi Đáp

Một câu hỏi cố định được đặt ra cho mọi video: *"Hãy mô tả nội dung tổng thể của video này dựa trên bản phiên âm. Trả lời bằng tiếng Việt, khoảng 3–5 câu."* Quá trình sinh bị giới hạn tại 512 token để so sánh công bằng.

D. Định Nghĩa Thang Đo Chuẩn

- $\text{ty_le_thoi_luong} = T_{\text{sum}}/T_{\text{orig}}$
- Giảm kích thước tệp: $1 - \text{size}_{\text{sum}}/\text{size}_{\text{orig}}$
- Độ bao phủ phiên âm: $\sum \Delta t$ của các đoạn Whisper là phân số thời lượng video
- Tỉ lệ giữ lại đoạn: $N_{\text{seg,tomtat}}/N_{\text{seg,goc}}$
- CLIP top-1: độ tương đồng cosine giữa truy vấn và khung hình khớp tốt nhất
- Tăng tốc Whisper: $t_{\text{orig}}/t_{\text{sum}}$

E. Kết Quả Định Lượng (10 Cặp Video)

Bảng V: Kết Quả Trung Bình Chuẩn VideoIntel (10 Cặp Video)

Thang đo	Giá trị
Tỉ lệ thời lượng (tóm tắt / gốc)	≈21,5%
Giảm kích thước tệp	≈76,8%
Tăng tốc Whisper	≈4,4×
Độ bao phủ phiên âm (gốc / tóm tắt)	≈93,8% / 94,2%
Tỉ lệ giữ lại đoạn	≈25,6%
Chênh lệch CLIP top-1 (tóm tắt − gốc)	+0,0015 (không đáng kể)
Hỏi đáp chấp nhận được (định tính)	Gốc 8/10, Tóm tắt 5/10

Bảng IX: Điểm CLIP Top-1 Trung Bình: Gốc so với Tóm Tắt (Ba Truy Vấn)

Truy vấn	Gốc	Tóm tắt	Chênh lệch
Person Speaking (PS)	0,2509	0,2524	+0,0015
Important Event (IE)	0,2354	0,2374	+0,0020
Diagram or Chart (DC)	0,2274	0,2271	−0,0003
Trung bình	0,2379	0,2390	+0,0015

Chênh lệch trung bình CLIP top-1 tổng thể (tóm tắt − gốc) là **+0,0015**, là **không đáng kể về mặt thống kê**.

F. Kết Quả Hỏi Đáp Định Tính

Đánh giá: **Chính xác** (chủ đề khớp, không có chi tiết sai thực tế), **Một phần** (đúng hướng nhưng thiếu chi tiết hoặc có thêm thông tin ảo giác), **Không chính xác** (lạc đề hoặc sai nội dung).

Tổng quan: Trên bản phiên âm gốc, **8/10** câu trả lời được chấp nhận. Trên bản phiên âm tóm tắt, chỉ **5/10** là Chính xác; 5 còn lại rơi vào Một phần hoặc Không chính xác.

Giải thích. Chất lượng hỏi đáp trên bản tóm tắt *không* theo dõi chất lượng tìm kiếm CLIP: mật độ phiên âm và độ trung thực chủ đề là các yếu tố quyết định. Hai trường hợp cực đoan là **video_01** (trôi chủ đề hoàn toàn) và **video_09** (9,5% đoạn giữ lại gây mất thông tin nghiêm trọng).

G. Hạn Chế và Khuyến Nghị

- Kích thước mẫu: 10 video; một LLM; một mẫu câu hỏi.
- Điểm CLIP top-1 không thay thế được đánh giá liên quan có nhãn người.
- **Khuyến nghị:** (i) đảm bảo số đoạn tối thiểu trước khi tin tưởng hỏi đáp; (ii) kiểm tra tính nhất quán chủ đề giữa các bản phiên âm; (iii) xác minh độ bao phủ âm thanh khi có dấu hiệu bất thường.

X. Tối Ưu Hóa Kiến Trúc và Huấn Luyện

Phần này mô tả một biến thể pipeline được tối ưu hóa, được đánh giá so với cấu hình **cơ sở** của Mục IV trên cùng tập kiểm tra SumMe/TVSum.

Bảng VI: Thời Lượng và Kích Thước Tệp theo Cặp Video

Video	Gốc (s)	TT (s)	Tỉ lệ	Gốc (MB)	TT (MB)	Giảm
video_01	351	76	21,7%	17,22	3,80	77,9%
video_02	1198	254	21,2%	75,29	15,90	78,9%
video_03	480	104	21,7%	25,86	4,75	81,6%
video_04	488	111	22,7%	21,48	8,76	59,2%
video_05	1555	342	22,0%	73,16	16,06	78,0%
video_06	927	193	20,8%	48,01	11,15	76,8%
video_07	1359	314	23,1%	71,41	16,05	77,5%
video_08	831	177	21,3%	49,93	10,43	79,1%
video_09	1054	210	19,9%	60,34	11,83	80,4%
video_10	1006	209	20,8%	54,61	11,77	78,4%
Trung bình	825	179	21,5%	50,6	11,1	76,8%

Bảng VII: Thời Gian Phiên Âm Whisper và Mã Hóa CLIP (60 Keyframe)

Video	W-Gốc (s)	W-TT (s)	Tăng tốc	C-Gốc (s)	C-TT (s)
video_01	109,29	50,52	2,2×	3,03	3,15
video_02	112,15	25,20	4,5×	3,45	3,32
video_03	97,64	15,91	6,1×	3,46	3,44
video_04	207,15	29,73	7,0×	3,16	3,09
video_05	132,18	36,23	3,6×	3,20	3,12
video_06	155,04	44,66	3,5×	3,31	3,21
video_07	194,76	44,11	4,4×	3,12	3,32
video_08	117,31	25,34	4,6×	3,07	2,99
video_09	148,50	33,30	4,5×	3,26	3,34
video_10	155,26	38,14	4,1×	3,13	3,13
Trung bình	142,9	34,3	4,4×	3,22	3,21

Bảng VIII: Độ Bao Phủ Phiên Âm và Tỉ Lệ Giữ Lại Đoạn

Video	Bao phủ Gốc	Bao phủ TT	Đoạn Gốc	Đoạn TT	% Giữ lại
video_01	98,4%	100,0%	103	31	30,1%
video_02	93,7%	99,4%	478	71	14,9%
video_03	93,1%	93,0%	89	19	21,3%
video_04	91,5%	97,7%	84	42	50,0%
video_05	96,1%	93,5%	320	138	43,1%
video_06	94,1%	92,3%	202	51	25,2%
video_07	88,7%	94,0%	400	81	20,3%
video_08	93,4%	85,3%	164	33	20,1%
video_09	92,5%	89,7%	378	36	9,5%
video_10	96,8%	97,2%	214	46	21,5%
Trung bình	93,8%	94,2%	243	55	25,6%

A. Giao Thức Đánh Giá

Cả hai checkpoint được đánh giá trên **cùng tập kiểm tra giữ lại**, với hạt giống ngẫu nhiên giống nhau, tỉ lệ tóm tắt r=0,35 và pipeline đánh giá giống nhau. Điều kiện tiên quyết là mô hình phải được tải với **cờ kiến trúc đúng**: biến thể tối ưu hóa ghép nối vector ngữ cảnh chú ý toàn cục $\mathbf{c}$ với trạng thái ẩn theo khung hình trước bộ tính điểm, tạo ra đầu vào bộ tính điểm 1024 chiều thay vì 512.

B. Kết Quả Định Lượng trên Tập Kiểm Tra

Bảng XI: Biến Thể Cơ Sở so với Tối Ưu Hóa: Thang Đo Tập Kiểm Tra

Thang đo	Cơ sở	Tối ưu hóa	Δ
Độ chính xác	0,4767	0,5293	+0,0526
Độ bao phủ	0,4767	0,5293	+0,0526
F-score	0,4767	0,5293	+0,0526
Chồng lấp thời gian	0,2347	0,3709	+0,1363

C. Các Thay Đổi Chính

Bốn thay đổi bổ sung được áp dụng kết hợp.

1) Kết Hợp Ngữ Cảnh Chú Ý trong Bộ Tính Điểm: **Cơ sở.** Bộ tính điểm theo khung hình chỉ nhận trạng thái ẩn BiLSTM cục bộ: $z_t = f_{\text{base}}(\mathbf{h}_t)$, lớp tuyến tính đầu tiên có 512 đơn vị đầu vào.

Bảng X: Đánh Giá Hỏi Đáp Định Tính theo Video (Bản Phiên Âm Tóm Tắt)

Video	Đánh giá	Nhận xét
video_01	Không chính xác	Gốc: tin tức Mỹ–Israel–Iran. Tóm tắt: chủ đề hoàn toàn khác (kháng sinh / hài hước) — lỗi chọn nội dung nghiêm trọng.
video_02	Chính xác	Cả hai đều đề cập Israel/Iran, năng lượng, vấn đề xã hội Mỹ — chủ đề khớp.
video_03	Một phần	Hướng thể thao đúng (FA Cup) nhưng thiếu chi tiết đội/cầu thủ cụ thể.
video_04	Chính xác	Cả hai đề cập lập kế hoạch kịch bản AI và rủi ro kiểm soát — khớp tốt.
video_05	Chính xác	BCI, vật liệu sinh học trong tóm tắt khớp nội dung điện tử thần kinh gốc.
video_06	Một phần	Hướng địa chính trị đúng nhưng thêm "tai nạn giao thông Việt Nam" không có trong gốc (ảo giác).
video_07	Một phần	Đúng về kinh tế/Trung Quốc nhưng thêm "cạnh tranh kinh tế Việt Nam" không liên quan.
video_08	Một phần	Đúng về Iran/Trump/Trung Quốc nhưng thêm bất động sản Trung Quốc và biểu tình New York lạc đề.
video_09	Một phần	Phần quốc tế xấp xỉ đúng; nội dung trong nước bị thiếu (chỉ ≈9,5% đoạn được giữ lại).
video_10	Chính xác	Cả hai đề cập vấn đề hàng hải Trung Đông — các chủ đề chính được bảo tồn.

Tối ưu hóa. Vector ngữ cảnh toàn cục $\mathbf{c}$ (giống nhau với mọi t, nhưng mã hóa toàn bộ phân phối chuỗi) được ghép nối với trạng thái cục bộ:

$$\mathbf{u}_t = \big[\mathbf{h}_t\,;\,\mathbf{c}\big] \in \mathbb{R}^{1024}, \qquad z_t = f_{\text{opt}}(\mathbf{u}_t). \tag{9}$$

Lưu ý quan trọng: checkpoint cơ sở và tối ưu hóa không tương thích trọng số tại lớp tính điểm; cần huấn luyện lại hoàn toàn với cờ kiến trúc đúng.

2) Lựa Chọn Keyshot Kết Hợp Chất Lượng–Đa Dạng: Sau làm mượt điểm cấp cảnh, ngân sách tổng $k_{\text{tot}} \approx \lceil r \cdot L \rceil$ được chia thành thành phần *chất lượng* và *đa dạng*:

$$k_q = \text{round}(\rho\, k_{\text{tot}}), \qquad k_d = k_{\text{tot}} - k_q, \qquad \rho \approx 0{,}7. \tag{10}$$

k_q cảnh được chọn tham lam theo thứ tự điểm giảm dần (tối đa hóa sự nổi bật), trong khi k_d vị trí còn lại được lấp đầy bởi các cảnh tối đa hóa độ bao phủ thời gian của các vùng chưa được đại diện.

3) Hàm Mất Mát Bao Phủ Đoạn Phụ Trợ: Hàm mất mát huấn luyện chính vẫn là BCE có mặt nạ (Pt. 2). Một *phạt đa dạng* phụ trợ ngăn mô hình tập trung xác suất dự đoán cao vào một vùng thời gian duy nhất. Video được chia thành K đoạn liên tiếp $\{S_j\}_{j=1}^{K}$. Điểm đại diện đoạn là xác suất dự đoán đỉnh trong mỗi đoạn:

$$m_j = \max_{t \in S_j} \sigma(z_{i,t}). \tag{11}$$

Hàm mất mát phụ trợ phạt phương sai cao qua các đại diện đoạn:

$$\mathcal{L}_{\text{div}} = \text{Var}(m_1, \ldots, m_K), \qquad \mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda\, \mathcal{L}_{\text{div}}, \tag{12}$$

trong đó $\lambda = \texttt{diversity_weight} \geq 0$.

4) Chính Quy Hóa và Lịch Trình Học Thích Nghi: **Tăng suy giảm trọng số.** Hệ số suy giảm trọng số trong AdamW tăng từ 10^{-5} (cơ sở) lên $\approx 10^{-4}$.

Lịch trình ReduceLROnPlateau. Lịch trình StepLR cố định theo epoch được thay thế bởi `ReduceLROnPlateau`, theo dõi hàm mất mát xác thực và nhân tốc độ học với hệ số < 1 khi không có cải thiện trong `patience` đánh giá liên tiếp [34].

D. Giải Thích Kết Quả

Bốn thay đổi được báo cáo như một hệ thống kết hợp trong Bảng XI; quy kết theo từng thành phần yêu cầu thực nghiệm cắt bỏ có kiểm soát với hạt giống và phân chia dữ liệu cố định, được để lại cho công việc tương lai. Định tính: kết hợp ngữ cảnh trong Pt. (9) cải thiện chất lượng xếp hạng cấp khung hình; hàm mất mát đa dạng trong Pt. (12) giảm tập trung thời gian; chiến lược keyshot kết hợp trong Pt. (10) cân bằng sự nổi bật với độ bao phủ; các thay đổi chính quy hóa và lịch trình ổn định huấn luyện và giảm overfitting—cùng nhau cải thiện cả bốn thang đo được báo cáo.

XI. Kết Luận

Báo cáo này trình bày một **BiLSTM đa phương thức với Chú Ý Thời Gian** sử dụng vector đặc trưng **2432 chiều**, được huấn luyện bằng học có giám sát ở tỉ lệ tóm tắt r=0,35. Các thực nghiệm cắt bỏ xác nhận đóng góp riêng lẻ của nhánh âm thanh-ngôn ngữ (+2,0 pp F-score), mã hóa hai chiều (+5,7 pp) và Chú Ý Thời Gian (+3,7 pp).

Biến thể tối ưu hóa (Mục X) cải thiện thêm F-score +5,3 pp và chồng lấp thời gian +13,6 pp so với cơ sở thông qua kết hợp ngữ cảnh chú ý, lựa chọn keyshot kết hợp, hàm mất mát bao phủ phụ trợ và chính quy hóa thích nghi.

Đánh giá **VideoIntel** chứng minh rằng **tìm kiếm ngữ nghĩa CLIP** trên bản tóm tắt bị **suy giảm không đáng kể**, trong khi **chất lượng hỏi đáp** phụ thuộc quan trọng vào mật độ phiên âm và độ chính xác chủ đề—phản ánh tóm tắt video như **nén có tổn hao** và nhấn mạnh nhu cầu **xác thực tác vụ hạ lưu** trước khi triển khai.

Phụ Lục

Phụ lục này báo cáo một **thực nghiệm hạ lưu** độc lập với việc huấn luyện BiLSTM trên SumMe/TVSum. Mục tiêu là đánh giá liệu các video từ pipeline tóm tắt có giữ lại đủ tín hiệu hành vi để huấn luyện bộ phát hiện sự kiện đơn giản, so với video gốc đầy đủ.

A. Động Lực và Giả Thuyết

Điều kiện A huấn luyện trên video đầy đủ; **Điều kiện B** huấn luyện trên các bản tóm tắt tương ứng. Nếu các cảnh giữ lại bao phủ các vùng chuyển động cao liên quan đến sự kiện, Điều kiện B có thể đạt MAE thời gian thấp hơn hoặc tương đương do chuỗi ngắn hơn và ít nhiễu hơn.

B. Định Nghĩa Tác Vụ

Đầu vào. Một tệp video đơn; hệ thống lấy mẫu khung ở tốc độ cố định (ví dụ: 4 fps) và tính vector đặc trưng thống kê không dùng mạng sâu.

Đầu ra. (1) *Phân loại nhị phân*: sự kiện có/không; (2) *Hồi quy thời gian*: nhãn thời gian sự kiện dự đoán $\hat{t}$ (giây).

Vector đặc trưng (mỗi video). Thời lượng, số khung lấy mẫu, trung bình và độ lệch chuẩn của độ lớn chuyển động liên khung, giá trị chuyển động đỉnh, thống kê độ sáng, và vị trí thời gian của đỉnh chuyển động.

C. Tập Dữ Liệu Thí Điểm

Bảng XII: Phân Chia Tập Dữ Liệu Thí Điểm cho Phát Hiện Sự Kiện

Phân chia	Video
Huấn luyện	31
Xác thực	8
Kiểm tra	6
Tổng cộng	**45**

Tất cả nhãn được gán thủ công. **Hạn chế:** mọi mẫu trong các phân chia hiện tại đều mang nhãn sự kiện dương; do đó độ chính xác và F1 không thông tin về phân biệt lớp âm. Thang đo so sánh trung tâm là **MAE thời gian** giữa hai điều kiện.

D. Kết Quả

Bảng XIII: Kết Quả Phát Hiện Sự Kiện: Điều Kiện A (Gốc) so với B (Tóm Tắt)

Phân chia	n	Acc / F1 (A / B)		MAE (s) (A / B)	
Huấn luyện	31	1,00 / 1,00	1,00 / 1,00	0,305	0,470
Xác thực	8	1,00 / 1,00	1,00 / 1,00	1,622	0,292
Kiểm tra	6	1,00 / 1,00	1,00 / 1,00	0,549	1,269

Trên tập **xác thực**, Điều kiện B đạt MAE thấp hơn; trên tập **kiểm tra**, Điều kiện A hoạt động tốt hơn. Với chỉ 8 và 6 video tương ứng, sự đảo ngược này không cho phép kết luận thống kê vững chắc.

Kết quả số cho tất cả các biến thể cắt bỏ—BiLSTM chỉ thị giác, BiLSTM đa phương thức đầy đủ, BiLSTM không có Chú Ý Thời Gian và UniLSTM một chiều—được báo cáo trong Bảng III của Mục IV. Tất cả các biến thể chia sẻ cùng giao thức đánh giá (phân chia cố định, tỉ lệ tóm tắt r=0,35, hậu xử lý giống nhau), cho phép quy kết trực tiếp sự khác biệt hiệu năng cho từng lựa chọn kiến trúc. Đóng góp tăng dần của nhánh đa phương thức (+2,0 pp F-score), Chú Ý Thời Gian (+3,7 pp) và mã hóa hai chiều (+5,7 pp) nhất quán với tài liệu rộng hơn về mô hình tóm tắt tuần tự [4], [7].

TÀI LIỆU

[1] E. Apostolidis, K. Mekkas, A. I. Patras, và I. Kompatsiaris, "PGL-SUM: A Novel Pointer-Generator Network for Extractive Video Summarization," in *Proc. IEEE Int. Symp. Multimedia (ISM)*, 2021.

[2] M. Gygli, H. Grabner, H. Riemenschneider, và L. Van Gool, "Creating summaries from user videos," in *ECCV*, vol. 8695, 2014, tr. 505–520.

[3] Y. Song, J. Vallmitjana, A. Stent, và A. Jaimes, "TVSum: Summarizing web videos using titles," in *CVPR*, 2015, tr. 5179–5187.

[4] J. Fajtl, H. S. Sokeh, V. Argyriou, D. Monekosso, và P. Remagnino, "Summarizing Videos with Attention (VASNet)," in *ACCV*, 2018.

[5] S. A. Ghauri *và cs.*, "MSVA: Multi-Stage Aggregated Transformer for Video Summarization," *arXiv:2104.11530*, 2021.

[6] B. Mahasseni, M. Lam, và S. Todorovic, "Unsupervised Video Summarization with Adversarial LSTM Networks (SUM-GAN)," in *CVPR*, 2017.

[7] K. Zhang, W.-L. Chao, F. Sha, và K. Grauman, "Video Summarization with Long Short-Term Memory (vsLSTM, dppLSTM)," in *ECCV*, 2016.

[8] K. Zhang, K. Grauman, và F. Sha, "Retrospective Encoders for Video Summarization (Cycle-SUM)," in *AAAI*, 2019.

[9] W. Zhu, J. Lu, J. Li, và J. Zhou, "DSNet: A Flexible Detect-to-Summarize Network for Video Summarization," *IEEE Trans. Image Process.*, 2021.

[10] Y. Zhu *và cs.*, "MHSCNet: Multi-Head Self-Attention Based Convolutional Network for Video Summarization," *arXiv:2204.08352*, 2022.

[11] K. He, X. Zhang, S. Ren, và J. Sun, "Deep Residual Learning for Image Recognition," in *CVPR*, 2016.

[12] S. Hochreiter và J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, tr. 1735–1780, 1997.

[13] A. Radford *và cs.*, "Learning Transferable Visual Models From Natural Language Supervision (CLIP)," in *ICML*, 2021.

[14] N. Reimers và I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *EMNLP*, 2019.

[15] A. Radford *và cs.*, "Robust Speech Recognition via Large-Scale Weak Supervision (Whisper)," in *ICML*, 2023.

[16] Ollama Developers, *Ollama: Run Large Language Models Locally*, https://ollama.com.

[17] FFmpeg Developers, *FFmpeg: A Complete, Cross-Platform Solution to Record, Convert and Stream Audio and Video*, https://ffmpeg.org.

[18] H. B. Haq *và cs.*, "Video summarization techniques: A review," *Math. Probl. Eng.*, vol. 2021, tr. 1–17, 2021.

[19] A. G. Money và H. Agius, "A survey on video summarization techniques," *Int. J. Comput. Appl.*, vol. 118, no. 11, tr. 25–31, 2015.

[20] T. Psallidas *và cs.*, "Multimodal summarization of user-generated videos," *Appl. Sci.*, vol. 11, no. 11, tr. 5260, 2021.

[21] S. Hu *và cs.*, "Video summarization based on feature fusion and data augmentation," *Computers*, vol. 12, no. 9, tr. 186, 2023.

[22] P. Kadam *và cs.*, "Recent challenges and opportunities in video summarization with machine learning algorithms," *IEEE Access*, vol. 10, tr. 122762–122785, 2022.

[23] E. Apostolidis *và cs.*, "Video summarization using deep neural networks: A survey," *Proc. IEEE*, vol. 109, no. 11, tr. 1838–1863, 2021.

[24] G. Bertasius, H. Wang, và L. Torresani, "Is Space-Time Attention All You Need for Video Understanding? (TimeSformer)," in *ICML*, 2021.

[25] Z. Liu *và cs.*, "Video Swin Transformer," in *CVPR*, 2022.

[26] J. Carreira và A. Zisserman, "Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset (I3D)," in *CVPR*, 2017.

[27] D. P. Kingma và J. Ba, "Adam: A Method for Stochastic Optimization," in *ICLR*, 2015.

[28] I. Loshchilov và F. Hutter, "Decoupled Weight Decay Regularization (AdamW)," in *ICLR*, 2019.

[29] H. Ji, M. Xu, và J. Yang, "Video Summarization with Attention-Based Encoder-Decoder Networks," *arXiv:1708.09545*, 2017.

[30] M. Gygli, H. Grabner, và L. Van Gool, "Video Summarization by Learning Submodular Mixtures of Objectives," in *CVPR*, 2015.

[31] H. Lin và J. Bilmes, "A Class of Submodular Functions for Document Summarization," in *Proc. NAACL*, 2011.

[32] R. Caruana, "Multitask Learning," *Machine Learning*, vol. 28, no. 1, tr. 41–75, 1997.

[33] I. Goodfellow, Y. Bengio, và A. Courville, *Deep Learning*. MIT Press, 2016.

[34] PyTorch Developers, "`ReduceLROnPlateau`," in *PyTorch Documentation (Stable)*, https://pytorch.org/docs/stable/generated/torch.optim.lr_scheduler.ReduceLROnPlateau.html.

[35] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, tr. 5–32, 2001.

[36] G. Bradski, "The OpenCV Library," *Dr. Dobb's Journal of Software Tools*, 2000.