Tóm Tắt Video Đa Phương Thức Qua Học Có Giám Sát: Multimodal BiLSTM với Temporal Attention

và Đánh Giá Ứng Dụng Phân Tích Nội Dung VideoIntel

Trần Hải Đức
MSSV: 23127173
Trường Đại học Khoa học Tự nhiên, VNU-HCM
thduc23@clc.fitus.edu.vn

Nguyễn Công Chiến
MSSV: 23127331
Trường Đại học Khoa học Tự nhiên, VNU-HCM
ncchien23@clc.fitus.edu.vn

***Abstract*—Báo cáo này trình bày một phương pháp tóm tắt video có giám sát, được đánh giá trên hai bộ benchmark SumMe và TVSum. Đặc trưng thị giác được trích xuất bằng backbone ResNet-50, trong khi đặc trưng ngữ nghĩa từ giọng nói được thu thập thông qua hệ thống nhận dạng giọng nói tự động Whisper kết hợp với bộ mã hóa câu SentenceBERT. Kiến trúc Bidirectional LSTM (BiLSTM) hai lớp kết hợp cơ chế Temporal Attention tạo ra điểm quan trọng cho từng frame. Quá trình inference sử dụng tỷ lệ tóm tắt cố định r=0,35 cùng với Gaussian smoothing, phân đoạn cảnh quay và mở rộng biên để tổng hợp bản tóm tắt động cuối cùng. Bên cạnh đó, ứng dụng VideoIntel—được xây dựng trên CLIP, Whisper và một LLM cục bộ—được dùng để đo lường khả năng tìm kiếm và hỏi-đáp khi thay thế video gốc bằng bản tóm tắt. Toàn bộ nội dung là tự chứa; không cần file nguồn bên ngoài.**

***Index Terms*—tóm tắt video, học có giám sát, BiLSTM, temporal attention, đa phương thức, SumMe, TVSum, CLIP, Whisper, hỏi-đáp video**

I. Giới Thiệu

A. Bài Toán Tóm Tắt Video

Tóm tắt video (video summarization) hướng đến việc tạo ra một biểu diễn cô đọng của video gốc, giữ lại nội dung quan trọng và mạch nội dung. Hai dạng đầu ra phổ biến là:

- **Tóm tắt tĩnh:** tập hợp các keyframe hoặc shot đại diện được chọn lọc.
- **Tóm tắt động:** file video ngắn hơn, được ghép từ các đoạn được chọn và giữ nguyên âm thanh đồng bộ.

Mục tiêu từ phía người dùng là *giảm thời gian xem* trong khi vẫn giữ lại phần lớn thông tin quan trọng; mục tiêu ở cấp độ hệ thống là *giảm chiều dữ liệu một cách có cấu trúc* thay vì nén đồng đều theo thời gian.

B. Bối Cảnh Phương Pháp

Các hướng tiếp cận hiện có bao gồm: phương pháp heuristic và clustering; mô hình tuần tự (LSTM, BiLSTM) kết hợp attention; kiến trúc Transformer; học tăng cường; và học tự giám sát. Các phương pháp **đa phương thức** xử lý đồng thời thị giác và tín hiệu âm thanh/giọng nói đặc biệt hiệu quả với các đoạn giàu ngữ nghĩa nhưng ít thay đổi về mặt hình ảnh—ví dụ như slide bài giảng có lời thuyết minh đi kèm.

C. Đóng Góp Của Báo Cáo

Các đóng góp cụ thể của báo cáo này bao gồm:

1) Pipeline **tóm tắt video đa phương thức có giám sát** được huấn luyện trên **SumMe** và **TVSum**, kết hợp đặc trưng thị giác và giọng nói.
2) Kiến trúc **BiLSTM** với **Temporal Attention** xử lý chuỗi đặc trưng đa phương thức 2432 chiều; nhánh giọng nói sử dụng **Whisper** (ASR) và **SentenceBERT**.
3) Bản **tóm tắt video động** V_{sum} với âm thanh đồng bộ, được ghép bằng `ffmpeg` tại tỷ lệ tóm tắt cố định $r = 0{,}35$.
4) Đánh giá bổ sung thông qua ứng dụng **VideoIntel**, đo lường chất lượng **tìm kiếm ngữ nghĩa** (CLIP) và **hỏi-đáp** (Whisper + LLM cục bộ) trên các cặp video gốc/tóm tắt.

D. Các Nghiên Cứu Liên Quan

Các khảo sát tổng quan [3]–[7] cung cấp cái nhìn rộng về pipeline cổ điển và deep learning. Pipeline tiêu chuẩn bao gồm **trích xuất đặc trưng cấp frame**, **ước tính điểm quan trọng**, và **chọn đoạn phim** trong giới hạn thời gian.

Với các phương pháp deep learning có giám sát, các biến thể **LSTM/BiLSTM** như vsLSTM và dppLSTM [11] mô hình hóa phụ thuộc thời gian; các cơ chế **attention** (VASNet [15], Temporal Attention trong bài này) làm nổi bật các vùng thời gian giàu thông tin. Kiến trúc **Transformer** [16] dựa trên self-attention đã truyền cảm hứng cho các biến thể encoder-only và encoder-decoder đầy đủ trong tóm tắt video [14], [17]. Các hướng không giám sát và đối kháng (SUM-GAN [21], SUM-GAN-AED [23], Cycle-SUM [22]) và các mô hình dựa trên Transformer (MSVA [19], PGL-SUM [18], MHSCNet [20]) cung cấp thêm các lựa chọn kiến trúc. **Graph Neural Network** ứng dụng cho lý luận không-thời gian [24] nắm bắt phụ thuộc cấp đối tượng mà các phương pháp cấp frame bỏ qua. Kết hợp **đa phương thức** thị giác và giọng nói là lĩnh vực nghiên cứu

tích cực [25], [26]; tóm tắt dẫn hướng ngôn ngữ qua CLIP [27] thể hiện khả năng tổng quát hóa zero-shot mạnh mẽ.

Ở cấp độ đặc trưng, **CNN ResNet** [28] cung cấp vector thị giác; nhánh văn bản dùng **Whisper** [29] và **Sentence-BERT** [30] để kết hợp cố định chiều. **CLIP** [31] cung cấp không gian embedding chung cho ảnh và văn bản phục vụ tìm kiếm ngữ nghĩa.

II. Phát Biểu Bài Toán

A. Đầu Vào

- Video đầu vào V ở định dạng chuẩn, độ dài tùy ý.
- Trong quá trình huấn luyện: với mỗi bước thời gian $t \in \{1, \dots, T\}$ được lấy mẫu, nhãn quan trọng vô hướng $y_t \in [0, 1]$ được suy ra từ annotation của SumMe/TVSum (chuẩn hóa theo quy ước từng dataset).

B. Đầu Ra

- **Tóm tắt tĩnh (phụ):** tập các keyframe hoặc shot được chọn.
- **Tóm tắt động (chính):** video V_{sum} có tổng thời lượng xấp xỉ $r \cdot |V|$, với $r = 0{,}35$ cố định tại inference. Bản tóm tắt được ghép từ các đoạn được chọn, giữ nguyên âm thanh gốc.

C. Ràng Buộc Triển Khai

Tóm tắt động là đầu ra chính vì nó phù hợp nhất với nhu cầu thực tế của người dùng (xem nhanh kèm âm thanh). Trích xuất âm thanh và ghép bằng `ffmpeg` được dùng xuyên suốt pipeline.

III. Nền Tảng Lý Thuyết và Công Thức Toán Học

A. Không Gian Đặc Trưng Đa Phương Thức

Tại mỗi bước thời gian t được lấy mẫu (ví dụ 2 fps), ta xây dựng vector đặc trưng:

$$\mathbf{x}_t = \begin{bmatrix} \mathbf{v}_t \\ \mathbf{a}_t \end{bmatrix} \in \mathbb{R}^{D_v + D_a}, \quad D_v = 2048,\ D_a = 384,\ D_v + D_a = 2432. \tag{1}$$

Trong đó $\mathbf{v}_t$ là đặc trưng thị giác từ CNN (ResNet-50) và $\mathbf{a}_t$ là đặc trưng ngữ nghĩa giọng nói đã căn chỉnh thời gian (Phần V).

B. Học Có Giám Sát và Nhãn Nhị Phân

Mô hình sinh ra logit $z_t \in \mathbb{R}$ cho mỗi frame. Xác suất ước tính là $\hat{y}_t = \sigma(z_t)$, với σ là hàm sigmoid. Nhãn gốc $y_t \in [0, 1]$ được **nhị phân hóa** tại ngưỡng 0,5 để thu được $\tilde{y}_t \in \{0, 1\}$ cho tính toán loss (BCEWithLogitsLoss). **Hàm loss** trung bình qua T bước là:

$$\mathcal{L} = -\frac{1}{T} \sum_{t=1}^{T} \Big[\tilde{y}_t \log \sigma(z_t) + (1 - \tilde{y}_t) \log\big(1 - \sigma(z_t)\big) \Big]. \tag{2}$$

C. Bidirectional LSTM (BiLSTM)

Với chuỗi đầu vào $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_T)$, LSTM xuôi sinh ra $\overrightarrow{\mathbf{h}}_t \in \mathbb{R}^H$ và LSTM ngược sinh ra $\overleftarrow{\mathbf{h}}_t \in \mathbb{R}^H$, với $H = 256$. Hidden state được nối ghép là:

$$\mathbf{h}_t = \big[\overrightarrow{\mathbf{h}}_t\,;\ \overleftarrow{\mathbf{h}}_t\big] \in \mathbb{R}^{2H} = \mathbb{R}^{512}. \tag{3}$$

Hai lớp BiLSTM chồng nhau làm sâu hơn biểu diễn; mỗi lớp xử lý chuỗi theo **cả hai chiều thời gian**, nên ước lượng quan trọng tại t phụ thuộc vào cả ngữ cảnh quá khứ lẫn tương lai.

D. Temporal Attention

Gọi $\mathbf{H} = [\mathbf{h}_1, \dots, \mathbf{h}_T] \in \mathbb{R}^{T \times 512}$. Điểm và trọng số attention được tính như sau:

$$e_t = \mathbf{u}^\top \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a), \quad \alpha_t = \frac{\exp(e_t)}{\sum_{k=1}^{T} \exp(e_k)}. \tag{4}$$

Vector ngữ cảnh tổng hợp toàn cục là:

$$\mathbf{c} = \sum_{t=1}^{T} \alpha_t\, \mathbf{h}_t. \tag{5}$$

Để giữ lại **logit cấp frame** cho chọn lọc shot, $\mathbf{h}_t$ được kết hợp với $\mathbf{c}$ qua nối ghép hoặc chiếu tuyến tính.

E. Lớp Đầu Ra

$$z_t = \mathbf{w}_o^\top \mathbf{h}_t^{\text{out}} + b_o, \tag{6}$$

trong đó $\mathbf{h}_t^{\text{out}}$ là biểu diễn sau attention. Sigmoid được áp dụng tại inference: $\hat{y}_t = \sigma(z_t)$.

F. Bộ Dữ Liệu và Chỉ Số Đánh Giá

- **SumMe** [1]: nhãn quan trọng cấp frame từ nhiều người chú thích.
- **TVSum** [2]: nhãn quan trọng cấp đoạn từ nhiều người chú thích.
- **F-score**: trung bình điều hòa của precision và recall trên các frame/đoạn được chọn so với ground-truth.
- **Precision / Recall**: tỷ lệ frame được chọn thực sự quan trọng / tỷ lệ frame quan trọng được chọn.
- **Temporal overlap**: tỷ lệ giao thoa thời gian giữa các đoạn dự đoán và ground-truth.

IV. Pipeline: Kiến Trúc Mô Hình và Forward Pass

A. Tổng Quan Các Module

Luồng dữ liệu trong pipeline như sau:

1) **Lấy mẫu frame** tại 2 fps; độ dài chuỗi giới hạn tại `max_seq_len` = 960 frame (≈8 phút).
2) **Visual backbone:** ResNet-50 trích xuất $\mathbf{v}_t \in \mathbb{R}^{2048}$.
3) **Nhánh âm thanh-ngôn ngữ:** `ffmpeg` → Whisper → SentenceBERT → $\mathbf{a}_t$ (Phần V).
4) **Nối ghép đặc trưng:** $\mathbf{x}_t = [\mathbf{v}_t; \mathbf{a}_t] \in \mathbb{R}^{2432}$.
5) **BiLSTM hai lớp**, hidden size 256 mỗi chiều → $\mathbf{h}_t \in \mathbb{R}^{512}$.
6) **Temporal Attention** → đầu tuyến tính → z_t.
7) Loss: **BCEWithLogitsLoss**; optimizer: **AdamW**; scheduler: **StepLR**.

B. Kích Thước Tensor và Batching

Các chuỗi dài hơn 960 bước được **cắt bớt**. Các batch sử dụng **padding và masking** để loss không được tính trên các vị trí padding. Mỗi bước thời gian hợp lệ mang vector đầu vào 2432 chiều.

C. Các Biến Thể Ablation

Table I: Các Biến Thể Ablation và Sự Khác Biệt Kiến Trúc

Biến thể	Thay đổi
Mô hình đầy đủ	$\mathbf{x}_t = [\mathbf{v}_t; \mathbf{a}_t]$, có Temporal Attention
Chỉ thị giác	Bỏ $\mathbf{a}_t$; giảm chiều đầu vào
Không Attention	Xóa Temporal Attention; BiLSTM + đầu tuyến tính
UniLSTM	`bidirectional=False`; LSTM một chiều

V. Pipeline: Nhánh Âm Thanh, Mã Hóa Văn Bản và Căn Chỉnh Thời Gian

A. Trích Xuất Âm Thanh

`ffmpeg` chuyển đổi track âm thanh của video sang định dạng **WAV** (mono, 16 kHz), đồng bộ với timeline video.

B. Nhận Dạng Giọng Nói Tự Động (Whisper)

Whisper [29] tạo ra các **token câu/đoạn**, mỗi token mang timestamp $(t_k^{\text{start}}, t_k^{\text{end}})$ và văn bản phiên âm.

C. Mã Hóa SentenceBERT

Mỗi đoạn phiên âm được mã hóa thành $\mathbf{s}_k \in \mathbb{R}^{384}$ bằng SentenceBERT [30].

D. Căn Chỉnh Cấp Frame

Với mỗi frame được lấy mẫu tại thời điểm tuyệt đối T_t:

- Nếu $T_t \in [t_k^{\text{start}}, t_k^{\text{end}}]$, gán $\mathbf{a}_t = \mathbf{s}_k$.
- Ngược lại: gán $\mathbf{a}_t = \mathbf{0}$ hoặc nội suy từ đoạn gần nhất.

E. Kết Hợp Đặc Trưng

$$\mathbf{x}_t = [\mathbf{v}_t;\, \mathbf{a}_t] \in \mathbb{R}^{2432}. \tag{7}$$

Nhánh âm thanh-ngôn ngữ tăng trọng số của các **đoạn giọng nói giàu ngữ nghĩa** ngay cả khi tín hiệu thị giác tương đối tĩnh.

VI. Pipeline: Huấn Luyện, Inference và Ghép Video

A. Huấn Luyện (Offline)

1) **Tiền xử lý:** lấy mẫu 2 fps; ResNet-50 → tensor thị giác; Whisper + SentenceBERT → đặc trưng âm thanh-văn bản căn chỉnh.
2) **Xây dựng** chuỗi $\mathbf{x}_t$; tạo batch có padding/masking.
3) **Forward pass:** $\mathbf{x}_{1:T} \to$ BiLSTM $\to$ Attention $\to z_{1:T}$.
4) **Backward pass:** tính $\mathcal{L}$ (Eq. 2); cập nhật bằng AdamW; áp dụng StepLR; early stopping; lưu `best.pt`.

B. Inference trên Video Mới

1) Trích xuất $\{\mathbf{v}_t\}$ và $\{\mathbf{a}_t\}$ như khi huấn luyện.
2) Forward pass $\to \hat{y}_t = \sigma(z_t)$.
3) **Gaussian smoothing** để giảm nhiễu thời gian.
4) **Phân đoạn shot** qua `keyshot.py`.
5) **Chọn shot** sao cho tổng thời lượng $\approx r \cdot |V|$, $r = 0{,}35$.
6) **Mở rộng biên** $\pm 1{,}5$ giây mỗi đoạn được chọn; gộp các đoạn gần nhau nếu cần.
7) `ffmpeg` cắt và ghép các đoạn thành V_{sum} với âm thanh đầy đủ.

VII. Siêu Tham Số và Cấu Hình Thực Nghiệm

Table II: Siêu Tham Số và Cấu Hình Thực Nghiệm

Thành phần	Giá trị / Ghi chú
Kiến trúc	Multimodal BiLSTM + Temporal Attention
Visual backbone	ResNet-50, $D_v = 2048$
Đặc trưng âm thanh-văn bản	Whisper + SentenceBERT, $D_a = 384$
Chiều đầu vào	$2432 = 2048 + 384$
Lấy mẫu frame	2 fps, `max_seq_len` = 960
Làm mượt	Gaussian, σ từ file cấu hình
Tỷ lệ tóm tắt	$r = 0{,}35$
Mở rộng biên	$\pm 1{,}5$ giây
Loss	BCEWithLogitsLoss
Optimizer	AdamW, lr $= 10^{-3}$, wd $= 10^{-5}$
Scheduler	StepLR (step = 15, γ=0,5)

VIII. Kết Quả Thực Nghiệm và Nghiên Cứu Ablation

A. Thiết Kế Nghiên Cứu Ablation

Một nghiên cứu ablation đánh giá mô hình bằng cách *giữ nguyên dataset, cách chia train/test và giao thức đánh giá*, đồng thời *bật hoặc tắt từng khối kiến trúc riêng lẻ*—ví dụ bỏ nhánh đặc trưng, xóa attention, hoặc chuyển chiều LSTM. So sánh chỉ số trước và sau mỗi lần xóa bỏ giúp trả lời câu hỏi: *thành phần này có mang tín hiệu hữu ích, hay chỉ làm tăng độ phức tạp?*

Bốn biến thể được xem xét với động cơ như sau.

Mô hình đầy đủ (Multimodal BiLSTM + Temporal Attention). Đây là kiến trúc đề xuất hoàn chỉnh: đặc trưng thị giác từ ResNet-50 được nối ghép với embedding phiên âm mã hóa bởi SentenceBERT-Whisper, và một BiLSTM hai lớp xử lý chuỗi chung dưới cơ chế Temporal Attention.

Chỉ thị giác (không có nhánh âm thanh). Tóm tắt video thường dựa chủ yếu vào nội dung thị giác; tuy nhiên, với tài liệu giàu lời nói như clip tin tức TVSum, nhánh ngôn ngữ có thể cung cấp tín hiệu ngữ cảnh không thể khôi phục chỉ từ frame. Bỏ $\mathbf{a}_t$ giúp cô lập *đóng góp biên của âm thanh/văn bản* so với baseline CNN chỉ thị giác [11].

Không có Temporal Attention. Module attention tổng hợp vector ngữ cảnh toàn cục $\mathbf{c}$, cho phép bộ chấm điểm cấp frame so sánh từng vị trí với phân phối toàn chuỗi. Xóa attention rút gọn kiến trúc thành BiLSTM theo sau bởi bộ chấm điểm tuyến tính trực tiếp, kiểm tra *sự cần thiết của pooling ngữ cảnh cấp chuỗi* [15].

UniLSTM (một chiều). BiLSTM cung cấp cho mỗi vị trí cả ngữ cảnh quá khứ lẫn tương lai, điều này đặc biệt

có giá trị cho bài toán chấm điểm quan trọng khi độ liên quan của một shot chỉ có thể đánh giá tương đối với những gì xuất hiện sau đó. Thay `bidirectional=True` bằng `bidirectional=False` giúp cô lập *lợi ích của mã hóa hai chiều* [11], [18].

Cả bốn biến thể đều được huấn luyện với cùng siêu tham số (Bảng II), cùng random seed, và cùng pipeline hậu xử lý (r=0,35, Gaussian smoothing, mở rộng biên $\pm$1,5 giây).

B. Giao Thức Đánh Giá

Nhãn ground-truth được nhị phân hóa dùng *cùng tỷ lệ top-k* với dự đoán (kiểm soát bởi `summary_ratio`). Hệ quả trực tiếp là số dự đoán dương và số frame ground-truth dương xấp xỉ bằng nhau, khiến **Precision và Recall hội tụ về cùng giá trị** trong tổng thể—đây là thuộc tính của giao thức đánh giá, không phải trùng hợp số học. F-score do đó là trung bình điều hòa của hai giá trị gần bằng nhau và xấp xỉ Precision $\approx$ Recall trong các lần chạy này. Temporal overlap được báo cáo riêng như IoU cấp frame giữa các đoạn dự đoán và ground-truth, và *không bị ảnh hưởng* bởi sự đối xứng nhị phân hóa top-k.

Điểm SumMe và TVSum được giữ riêng biệt xuyên suốt, vì hai dataset khác nhau đáng kể về độ dài video, phong cách chú thích và miền nội dung; gộp chúng thành một con số sẽ che khuất hành vi đặc thù từng dataset.

C. Kết Quả Ablation Định Lượng

Table III: Nghiên Cứu Ablation: F-Score, Precision/Recall và Temporal Overlap (%)

Biến thể	SumMe F (%)	TVSum F (%)	P/R (%)	Overlap (%)
Mô hình đầy đủ	26,9	60,1	47,7	23,5
Chỉ thị giác	31,4	59,7	49,1	33,3
Không Attention	34,9	63,7	52,9	27,4
UniLSTM	35,4	63,1	52,7	37,3

D. Phân Tích và Diễn Giải

Một số quan sát đáng chú ý.

Sự không đối xứng giữa hai dataset. F-score trên TVSum nhất quán cao hơn SumMe trên tất cả các biến thể khoảng 27–28 điểm phần trăm. Điều này phản ánh sự khác biệt cơ bản giữa hai benchmark: video TVSum dài hơn và nhãn quan trọng—được suy ra từ tiêu đề video web—có xu hướng tập trung hơn, khiến việc chọn top-k dễ hơn. SumMe sử dụng điểm cấp frame từ crowdsourcing với mức độ bất đồng giữa người chú thích cao hơn, điều này làm tăng phương sai đánh giá [1], [2]. Kết quả trên một benchmark không nên dùng để dự đoán hiệu suất tuyệt đối trên benchmark kia.

Mô hình đầy đủ không xếp hạng nhất trên SumMe. Mô hình đa phương thức đầy đủ đạt F-score SumMe thấp hơn các biến thể chỉ thị giác, không attention và UniLSTM trong lần chạy này. Kết quả này phù hợp với các hiện tượng đã biết trong học đa phương thức: một kiến trúc phong phú hơn có nhiều tham số hơn và cần regularization, điều chỉnh learning rate và early stopping cẩn thận hơn; với ngân sách huấn luyện cố định, các biến thể đơn giản hơn có thể hội tụ đến điểm tối ưu cục bộ tốt hơn trên dataset nhỏ như SumMe (dưới 25 video trong split chuẩn) [18]. Thêm vào đó, nếu phiên âm âm thanh trong tập SumMe thưa thớt hoặc không căn chỉnh tốt (SumMe chứa video ngắn do người dùng tạo, nhiều video không có lời tường thuật liên tục), nhánh âm thanh gây ra nhiễu thay vì tín hiệu. Một so sánh chặt chẽ cần nhiều seed với kiểm định ý nghĩa thống kê; kết quả một seed hiện tại nên được hiểu là *kết quả cụ thể có thể tái tạo* chứ không phải quy luật phổ quát.

Precision bằng Recall trong cột P/R tổng hợp. Như giải thích ở Phần VIII.B, sự đối xứng nhị phân hóa top-k của bộ đánh giá khiến tổng số dương của dự đoán và ground-truth xấp xỉ bằng nhau, nên Precision $\approx$ Recall $\approx$ F-score trong cột chỉ số kết hợp.

Temporal overlap. Biến thể UniLSTM đạt temporal overlap cao nhất (37,3%), tiếp theo là chỉ thị giác (33,3%). Mô hình đầy đủ đạt overlap thấp nhất (23,5%). Một cách giải thích là cơ chế attention của mô hình đầy đủ tập trung dự đoán điểm cao vào ít vùng thời gian ngắn hơn, tạo ra tóm tắt thưa nhưng phân biệt hơn. Một giải thích khác là nhánh âm thanh dịch chuyển đỉnh điểm về phía các vùng dày đặc lời nói không trùng khớp với biên shot ground-truth trong split này.

Hàm ý cho thiết kế kiến trúc. Kết quả ablation cho thấy *các lựa chọn thiết kế kiến trúc tương tác với đặc điểm dataset* theo cách không tầm thường. Nhánh âm thanh cải thiện hiệu suất TVSum (+0,4 điểm so với chỉ thị giác, trên tập nội dung giàu ngữ nghĩa hơn), nhưng có vẻ ảnh hưởng tiêu cực đến SumMe ($-4{,}5$ điểm). Các phát hiện này gợi ý rằng với *corpus hỗn hợp hoặc nhiều lời kể*, đặc trưng đa phương thức có lợi, trong khi với *nội dung động mạnh, ít lời nói*, mô hình đơn phương thức đơn giản hơn có thể được ưu tiên.

E. So Sánh Với Các Phương Pháp Đã Công Bố

Table IV: So Sánh Với Các Phương Pháp Đã Công Bố trên SumMe và TVSum (F-Score, %)

Phương pháp	Năm	Loại	SumMe	TVSum
vsLSTM [11]	2016	Có giám sát	37,6	54,2
dppLSTM [11]	2016	Có giám sát	38,6	54,7
SUM-GAN [21]	2017	Không giám sát	38,7	50,8
Cycle-SUM [22]	2019	Không giám sát	41,9	57,6
VASNet [15]	2018	Có giám sát	49,6	61,4
DSNet [36]	2020	Có giám sát	51,2	61,9
MSVA [19]	2021	Có giám sát	53,4	61,5
PGL-SUM [18]	2021	Có giám sát	57,1	62,7
SUM-GDA	2020	—	56,3	60,7
Bài này (mô hình đầy đủ)	—	Có giám sát	**26,9**	**60,1**

Cần cẩn thận khi so sánh trực tiếp do sự khác biệt về cách chia dataset, tỷ lệ tóm tắt và chiến lược hậu xử lý. F-score TVSum đạt 60,1% cạnh tranh với vsLSTM (54,2%) và tiệm cận VASNet (61,4%), trong khi hiệu suất SumMe vẫn thấp hơn các baseline đã công bố, nhất quán với thảo luận về độ nhạy dataset ở trên.

F. So Sánh Với Mục Tiêu Ban Đầu

Mục tiêu ban đầu là F-score $\geq 0{,}43$ trên SumMe và $\geq 0{,}55$ trên TVSum. Kết quả TVSum của mô hình đầy đủ đạt **0,601**,

vượt ngưỡng TVSum. Kết quả SumMe đạt 0,269, thấp hơn 0,43, phản ánh độ nhạy cao của hiệu suất SumMe với cách chia dataset, ngân sách huấn luyện và nhiễu từ nhánh âm thanh trên video ngắn do người dùng tạo.

IX. Ứng Dụng Phân Tích Nội Dung VideoIntel

A. Động Cơ và Giả Thuyết Hoạt Động

Pipeline tóm tắt tạo ra file **nhỏ hơn và nhẹ hơn**, nhưng có thể:

1) **Giảm chi phí:** thời gian phiên âm giảm cùng với âm thanh ngắn hơn.
2) **Giảm thông tin:** mất đoạn lời nói hoặc lựa chọn không đúng chủ đề → **drift ngữ nghĩa**.

VideoIntel đo lường cả hai hiệu ứng trên **các cặp video (gốc, tóm tắt)** bằng: lập chỉ mục → Tìm kiếm → Hỏi-đáp.

Giả định kỹ thuật: **CLIP** (ViT-B/32) cung cấp không gian embedding chung cho văn bản và frame; **Whisper** cung cấp phiên âm; **LLM cục bộ (Ollama)** chỉ dựa vào phiên âm—phiên âm ngắn hoặc lạc chủ đề có thể gây **ảo giác (hallucination)**.

B. Bài Toán Tìm Kiếm

Sơ đồ tính điểm là:

$$\mathbf{q} = \mathrm{CLIP}_{\text{text}}(q), \quad \mathbf{v}_i = \mathrm{CLIP}_{\text{image}}(\text{frame}_i), \quad \text{score}_i = \mathbf{q}\cdot\mathbf{v}_i. \tag{8}$$

Ba câu truy vấn tiếng Anh cố định đánh giá CLIP top-1 score để ước tính **tính đại diện thị giác**: "Person Speaking" (PS), "Important Event" (IE), và "Diagram or Chart" (DC).

C. Bài Toán Hỏi-Đáp

Một câu hỏi cố định được đặt ra cho mỗi video: *"Hãy mô tả nội dung tổng thể của video này dựa trên phiên âm. Trả lời bằng tiếng Việt, khoảng 3–5 câu."* Sinh tối đa 512 token để so sánh công bằng.

D. Định Nghĩa Chỉ Số Benchmark

- $\text{duration_ratio} = T_{\text{sum}}/T_{\text{orig}}$
- Giảm kích thước file: $1 - \text{size}_{\text{sum}}/\text{size}_{\text{orig}}$
- Độ phủ phiên âm: $\sum \Delta t$ các đoạn Whisper theo tỷ lệ thời lượng video
- Tỷ lệ giữ lại đoạn: $N_{\text{seg,summ}}/N_{\text{seg,orig}}$
- CLIP top-1: cosine similarity giữa truy vấn và frame khớp tốt nhất
- Tăng tốc Whisper: $t_{\text{orig}}/t_{\text{sum}}$

E. Kết Quả Định Lượng (10 Cặp Video)

Table V: Kết Quả Trung Bình Benchmark VideoIntel (10 Cặp Video)

Chỉ số	Giá trị
Tỷ lệ thời lượng (tóm tắt / gốc)	≈21,5%
Giảm kích thước file	≈76,8%
Tăng tốc Whisper	≈4,4×
Độ phủ phiên âm (gốc / tóm tắt)	≈93,8% / 94,2%
Tỷ lệ giữ lại đoạn	≈25,6%
Chênh lệch CLIP top-1 (tóm tắt − gốc)	+0,0015 (không đáng kể)
Hỏi-đáp chấp nhận được (định tính)	Gốc 8/10, Tóm tắt 5/10

Table VI: Thời Lượng và Kích Thước File Theo Từng Cặp Video

Video	Gốc (s)	Tóm tắt (s)	Tỷ lệ	Gốc (MB)	Tóm tắt (MB)	Giảm
video_01	351	76	21,7%	17,22	3,80	77,9%
video_02	1198	254	21,2%	75,29	15,90	78,9%
video_03	480	104	21,7%	25,86	4,75	81,6%
video_04	488	111	22,7%	21,48	8,76	59,2%
video_05	1555	342	22,0%	73,16	16,06	78,0%
video_06	927	193	20,8%	48,01	11,15	76,8%
video_07	1359	314	23,1%	71,41	16,05	77,5%
video_08	831	177	21,3%	49,93	10,43	79,1%
video_09	1054	210	19,9%	60,34	11,83	80,4%
video_10	1006	209	20,8%	54,61	11,77	78,4%
TB.	825	179	21,5%	50,6	11,1	76,8%

Table VII: Thời Gian Phiên Âm Whisper và Mã Hóa CLIP (60 Keyframe)

Video	W-Gốc (s)	W-TT (s)	Tăng tốc	C-Gốc (s)	C-TT (s)
video_01	109,29	50,52	2,2×	3,03	3,15
video_02	112,15	25,20	4,5×	3,45	3,32
video_03	97,64	15,91	6,1×	3,46	3,44
video_04	207,15	29,73	7,0×	3,16	3,09
video_05	132,18	36,23	3,6×	3,20	3,12
video_06	155,04	44,66	3,5×	3,31	3,21
video_07	194,76	44,11	4,4×	3,12	3,32
video_08	117,31	25,34	4,6×	3,07	2,99
video_09	148,50	33,30	4,5×	3,26	3,34
video_10	155,26	38,14	4,1×	3,13	3,13
TB.	142,9	34,3	4,4×	3,22	3,21

Table VIII: Độ Phủ Phiên Âm và Tỷ Lệ Giữ Lại Đoạn

Video	Phủ Gốc	Phủ TT	Đoạn Gốc	Đoạn TT	% Giữ lại
video_01	98,4%	100,0%	103	31	30,1%
video_02	93,7%	99,4%	478	71	14,9%
video_03	93,1%	93,0%	89	19	21,3%
video_04	91,5%	97,7%	84	42	50,0%
video_05	96,1%	93,5%	320	138	43,1%
video_06	94,1%	92,3%	202	51	25,2%
video_07	88,7%	94,0%	400	81	20,3%
video_08	93,4%	85,3%	164	33	20,1%
video_09	92,5%	89,7%	378	36	9,5%
video_10	96,8%	97,2%	214	46	21,5%
TB.	93,8%	94,2%	243	55	25,6%

Table IX: CLIP Top-1 Trung Bình: Gốc vs. Tóm Tắt (Ba Câu Truy Vấn)

Câu truy vấn	Gốc	Tóm tắt	Chênh lệch
Person Speaking (PS)	0,2509	0,2524	+0,0015
Important Event (IE)	0,2354	0,2374	+0,0020
Diagram or Chart (DC)	0,2274	0,2271	−0,0003
Trung bình	0,2379	0,2390	+0,0015

Chênh lệch CLIP top-1 trung bình tổng thể (tóm tắt − gốc) là **+0,0015**, **không đáng kể về mặt thống kê**.

F. Kết Quả Hỏi-Đáp Định Tính

Mức đánh giá: **Chính xác** (chủ đề khớp, không có chi tiết sai thực tế), **Một phần** (hướng đúng nhưng thiếu chi tiết hoặc có thêm nội dung ảo giác), **Sai** (lạc chủ đề hoặc nội dung sai).

Tổng thể: Trên phiên âm gốc, **8/10** câu trả lời chấp nhận được. Trên phiên âm tóm tắt, chỉ **5/10** đạt mức Chính xác; 5 câu còn lại rơi vào Một phần hoặc Sai.

Table X: Đánh Giá Hỏi-Đáp Định Tính Theo Từng Video (Phiên Âm Tóm Tắt)

Video	Đánh giá	Quan sát
video_01	Sai	Gốc: tin tức Mỹ–Israel–Iran. Tóm tắt: chủ đề hoàn toàn khác (kháng sinh / hài kịch) — lỗi lựa chọn nội dung nghiêm trọng.
video_02	Chính xác	Cả hai đều đề cập Israel/Iran, năng lượng, vấn đề xã hội Mỹ — chủ đề khớp.
video_03	Một phần	Đúng hướng thể thao (FA Cup) nhưng thiếu chi tiết về đội/cầu thủ.
video_04	Chính xác	Cả hai đều đề cập lập kế hoạch kịch bản AI và rủi ro kiểm soát — căn chỉnh tốt.
video_05	Chính xác	BCI, vật liệu sinh học trong tóm tắt khớp với nội dung điện tử thần kinh trong bản gốc.
video_06	Một phần	Đúng hướng địa chính trị nhưng thêm "tai nạn giao thông Việt Nam" không có trong bản gốc (ảo giác).
video_07	Một phần	Đúng về kinh tế/Trung Quốc nhưng thêm "cạnh tranh kinh tế Việt Nam" không liên quan.
video_08	Một phần	Đúng về Iran/Trump/Trung Quốc nhưng thêm bất động sản Trung Quốc và biểu tình New York lạc đề.
video_09	Một phần	Phần quốc tế xấp xỉ đúng; nội dung trong nước bị thiếu (chỉ ≈9,5% đoạn được giữ lại).
video_10	Chính xác	Cả hai đều đề cập các vấn đề hàng hải Trung Đông — chủ đề chính được giữ lại.

Nhận xét. Chất lượng hỏi-đáp trên tóm tắt *không* theo sát chất lượng tìm kiếm CLIP: mật độ phiên âm và độ trung thực chủ đề mới là yếu tố quyết định. Hai cực đoan là **video_01** (drift chủ đề hoàn toàn) và **video_09** (9,5% đoạn được giữ lại gây mất thông tin nghiêm trọng).

G. Giới Hạn và Khuyến Nghị

- Kích thước mẫu: 10 video; một LLM; một mẫu câu hỏi.
- CLIP top-1 không thay thế được độ liên quan do người gán nhãn.
- **Khuyến nghị:** (i) yêu cầu số đoạn tối thiểu trước khi tin tưởng kết quả hỏi-đáp; (ii) kiểm tra tính nhất quán chủ đề giữa các phiên âm; (iii) xác minh độ phủ âm thanh khi có giảm đột ngột bất thường.

X. Tối Ưu Hóa Kiến Trúc và Huấn Luyện

Phần này mô tả bốn sửa đổi có mục tiêu đối với kiến trúc baseline của Phần IV, áp dụng chung để tạo thành một *biến thể tối ưu hóa* được đánh giá trên cùng split test SumMe/TVSum. Mỗi sửa đổi giải quyết một bottleneck cụ thể và có thể xác định trong baseline, dựa trên các nguyên lý lý thuyết đã được thiết lập và các nghiên cứu trước về tóm tắt video, huấn luyện đa mục tiêu và tối ưu hóa deep learning.

A. Giao Thức Đánh Giá và Tóm Tắt Baseline

Cả baseline lẫn checkpoint tối ưu hóa đều được đánh giá trên **cùng split test giữ lại**, với random seed giống nhau, tỷ lệ tóm tắt r=0,35 và pipeline hậu xử lý giống nhau (Gaussian smoothing, mở rộng biên $\pm$1,5 giây và ghép bằng `ffmpeg`).

Bộ chấm điểm **baseline** chỉ nhận hidden state BiLSTM cục bộ cấp frame $\mathbf{h}_t \in \mathbb{R}^{512}$:

$$z_t^{\text{base}} = \mathbf{w}_o^\top \mathbf{h}_t + b_o, \tag{9}$$

được huấn luyện với masked binary cross-entropy loss $\mathcal{L}_{\text{BCE}}$ (Eq. 2), AdamW với weight decay 10^{-5} và scheduler StepLR giảm một nửa learning rate mỗi 15 epoch bất kể hành vi validation loss.

B. Sửa Đổi 1: Kết Hợp Ngữ Cảnh Attention Trong Bộ Chấm Điểm

1) Động Cơ và Nhận Thức Lý Thuyết: Phương trình (9) chấm điểm frame t chỉ dùng *ngữ cảnh cục bộ*: hidden state BiLSTM $\mathbf{h}_t$ mã hóa vùng lân cận của t, nhưng bộ chấm điểm không có quyền truy cập tường minh vào *phân phối toàn cục* nội dung trong toàn clip. Đây là hạn chế cơ bản: cùng một mẫu chuyển động hoặc lời nói có thể rất nổi bật trong clip ngắn nhưng bình thường trong phim tài liệu hai giờ.

Các kiến trúc encoder-decoder tăng cường attention cho tóm tắt video [13], [15] giải quyết điều này bằng cách định tuyến tường minh vector ngữ cảnh tổng hợp toàn cục vào lớp chấm điểm. Ngữ cảnh toàn cục $\mathbf{c} = \sum_t \alpha_t \mathbf{h}_t$ mã hóa *clip nói về gì trung bình*, được trọng số bởi điểm attention; khi trạng thái cục bộ $\mathbf{h}_t$ của frame được nối ghép với $\mathbf{c}$, bộ chấm điểm có thể học các quy tắc: "frame t nổi bật *vì nó khác thường so với trung bình clip*", hoặc ngược lại, "nó không quan trọng *vì nó chỉ lặp lại mẫu chủ đạo.*" Lý luận so sánh này chính xác là phán đoán mà người biên tập áp dụng khi chọn highlight.

2) Công Thức Toán Học: Gọi $\mathbf{c} \in \mathbb{R}^{512}$ là vector ngữ cảnh Temporal Attention (giống nhau với mọi t nhưng mã hóa toàn chuỗi):

$$\mathbf{u}_t = \big[\mathbf{h}_t\,;\,\mathbf{c}\big] \in \mathbb{R}^{1024}, \qquad z_t^{\text{opt}} = \mathbf{W}_o\,\mathbf{u}_t + b_o, \tag{10}$$

trong đó $\mathbf{W}_o \in \mathbb{R}^{1\times 1024}$. Vector nối ghép $\mathbf{u}_t$ cho phép lớp tuyến tính đầu tiên của bộ chấm điểm mô hình hóa tương tác nhân giữa biểu diễn cục bộ và toàn cục.

3) Hệ Quả Triển Khai: Vì ma trận trọng số đầu tiên của bộ chấm điểm thay đổi shape từ $\mathbb{R}^{1\times 512}$ (baseline) sang $\mathbb{R}^{1\times 1024}$ (tối ưu hóa), hai checkpoint **không tương thích về trọng số tại lớp chấm điểm**. Phải huấn luyện lại hoàn toàn với cờ `use_context_fusion` đúng trước khi đánh giá.

C. Sửa Đổi 2: Chọn Keyshot Kết Hợp Chất Lượng–Đa Dạng

1) Động Cơ và Nhận Thức Lý Thuyết: Hậu xử lý baseline chọn top-k shot bằng *xếp hạng tham lam thuần túy*: các shot được sắp xếp theo điểm frame trung bình đã làm mượt và những shot có điểm cao nhất được chọn cho đến khi đủ ngân sách thời lượng $r \cdot |V|$. Chiến lược này tối đa hóa saliency cấp shot nhưng có một failure mode nổi tiếng: nếu mô hình gán điểm cao cho một *cụm thời gian nhỏ* (ví dụ điểm cao nhất của bài giảng), toàn bộ ngân sách có thể bị tiêu hết vào cụm

đó, tạo ra tóm tắt chỉ bao gồm một phần nhỏ span thời gian của clip.

Sự đánh đổi giữa *saliency* và *độ phủ thời gian* là chủ đề trung tâm trong tối ưu hóa submodular cho tóm tắt [41], [42]. Chiến lược kết hợp dưới đây xấp xỉ chọn lọc submodular nhận thức coverage mà không tốn chi phí tính toán của tối ưu hóa submodular đầy đủ.

2) Công Thức Toán Học: Sau khi làm mượt điểm cấp shot, tổng ngân sách frame là $k_{\text{tot}} \approx \lceil r \cdot L \rceil$. Định nghĩa phân số chất lượng $\rho \in (0, 1)$ (mặc định $\rho = 0{,}7$):

$$k_q = \text{round}(\rho\, k_{\text{tot}}), \qquad k_d = k_{\text{tot}} - k_q. \tag{11}$$

Pha 1 (chất lượng): Chọn k_q shot có điểm cao nhất theo thứ tự giảm dần. Gọi tập này là $\mathcal{S}_q$.

Pha 2 (đa dạng): Chia timeline video thành B bin thời gian bằng nhau. Với mỗi bin $b \notin \{\text{bin đã được phủ bởi } \mathcal{S}_q\}$, thêm shot có điểm cao nhất chưa được chọn từ bin b cho đến khi thêm đủ k_d shot, tạo thành $\mathcal{S}_d$.

Tập chọn cuối là $\mathcal{S} = \mathcal{S}_q \cup \mathcal{S}_d$. Điều này đảm bảo ít nhất $B - |\mathcal{S}_q|$ vùng thời gian riêng biệt được phủ.

3) Cân Nhắc Thực Tế: Đặt $\rho = 1$ khôi phục lại greedy top-k thuần túy; đặt $\rho = 0$ tạo ra coverage đồng đều bất buộc bất kể chất lượng. Giá trị trung gian cung cấp phép nội suy mượt. Lựa chọn $\rho = 0{,}7$ được thúc đẩy bởi quan sát thực nghiệm rằng mật độ annotation TVSum không đồng đều và có xu hướng nghiêng về phần đầu và cuối của mỗi video; phân bổ 30% ngân sách cho coverage ngăn chặn việc đại diện kém hệ thống các phần đuôi video.

D. Sửa Đổi 3: Loss Phủ Đoạn Phụ Trợ

1) Động Cơ và Nhận Thức Lý Thuyết: Mục tiêu huấn luyện baseline (masked BCE, Eq. 2) là loss pointwise thuần túy: nó đánh giá từng frame độc lập và không phạt các *thuộc tính cấu trúc* của phân phối điểm dự đoán. Mô hình huấn luyện với BCE thuần túy có thể đạt điểm tối ưu cục bộ bằng cách gán xác suất cao cho một đoạn ngắn và xác suất gần bằng không ở mọi nơi khác.

Huấn luyện đa mục tiêu với tín hiệu giám sát phụ trợ là kỹ thuật chuẩn để đưa vào các bias quy nạp cấu trúc mà loss chính không thể diễn đạt [43]. Penalty đa dạng phụ trợ dưới đây hoạt động như một regularizer cấp list: thay vì đánh giá điểm từng frame riêng lẻ, nó đánh giá *phân phối điểm đỉnh theo các đoạn thời gian*, khuyến khích mô hình trải đều độ tự tin dự đoán trên toàn video.

2) Công Thức Toán Học: Chia chuỗi T frame thành K đoạn liên tiếp không chồng nhau $\{S_j\}_{j=1}^{K}$ có độ dài bằng nhau (kiểm soát bởi `n_segments`, mặc định $K = 10$). Định nghĩa *điểm đỉnh đoạn* là xác suất dự đoán cao nhất trong mỗi đoạn:

$$m_j = \max_{t \in S_j} \sigma(z_t), \qquad j = 1, \ldots, K. \tag{12}$$

Loss đa dạng phụ trợ phạt phương sai cao trong điểm đỉnh đoạn:

$$\mathcal{L}_{\text{div}} = \text{Var}(m_1, \ldots, m_K) = \frac{1}{K} \sum_{j=1}^{K} (m_j - \bar{m})^2, \quad \bar{m} = \frac{1}{K} \sum_{j} m_j. \tag{13}$$

Loss tổng là kết hợp có trọng số:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{BCE}} + \lambda\, \mathcal{L}_{\text{div}}, \tag{14}$$

với $\lambda = \texttt{diversity_weight} \geq 0$.

3) Phân Tích Hành Vi: Gradient của $\mathcal{L}_{\text{div}}$ theo z_t với $t \in \arg\max_{t \in S_j} \sigma(z_t)$ là:

$$\frac{\partial \mathcal{L}_{\text{div}}}{\partial z_t} = \frac{2\lambda}{K} (m_j - \bar{m})\, m_j (1 - m_j), \tag{15}$$

dương với đoạn có đỉnh trên trung bình (đẩy điểm cực đại xuống) và âm với đoạn dưới trung bình (đẩy điểm cực đại lên). Hiệu ứng tổng là "làm phẳng" phân phối đỉnh độ tự tin đoạn—mô hình được khuyến khích tìm frame có điểm cao cục bộ trong từng vùng thời gian thay vì hội tụ vào một vùng chủ đạo duy nhất.

4) Độ Nhạy Siêu Tham Số: Đặt $\lambda = 0$ khôi phục baseline. λ quá lớn khiến loss đa dạng chiếm ưu thế, làm giảm chất lượng xếp hạng chính. Trong thực tế, $\lambda \in [0{,}01, 0{,}1]$ cung cấp dải hữu ích trên SumMe/TVSum; giá trị tối ưu nên được tinh chỉnh trên validation set.

E. Sửa Đổi 4: Regularization và Lịch Học Thích Ứng

1) Động Cơ và Nhận Thức Lý Thuyết: Hai sửa đổi trước (context fusion và loss phụ trợ) cùng tăng capacity mô hình hiệu quả: bộ chấm điểm giờ hoạt động trên đầu vào 1024 chiều (so với 512 trong baseline), và tín hiệu gradient bao gồm thêm một thành phần cấu trúc. Nếu không có thay đổi tương ứng về regularization và lịch learning rate, mô hình tối ưu hóa đối mặt với rủi ro overfitting tăng cao—đặc biệt trên SumMe với ít hơn 25 video huấn luyện trong split chuẩn.

Hơn nữa, StepLR baseline giảm learning rate theo hệ số cố định mỗi 15 epoch, *bất kể mô hình đã hội tụ hay vẫn đang cải thiện*. Cả hai hành vi đều có thể tránh được với một scheduler *thích ứng* giám sát trực tiếp validation loss [40].

2) Tăng Weight Decay (AdamW): AdamW [38] tách weight decay khỏi scaling gradient thích ứng của Adam. Trong baseline, hệ số weight decay là $\lambda_{\text{wd}} = 10^{-5}$. Trong biến thể tối ưu hóa, nó được tăng lên $\lambda_{\text{wd}} = 10^{-4}$.

Động lực gồm hai phần: Thứ nhất, bộ chấm điểm 1024 chiều có gấp đôi số tham số tại lớp đầu ra, tăng capacity thô cho overfitting. Thứ hai, loss đa dạng đưa vào tín hiệu gradient bổ sung có thể khiến độ lớn trọng số tăng nhanh trong các epoch đầu; weight decay mạnh hơn kiềm chế sự tăng trưởng này.

3) Scheduler ReduceLROnPlateau: Baseline StepLR áp dụng decay cố định:

$$\eta_k = \eta_0 \cdot \gamma^{\lfloor k/\text{step} \rfloor}, \quad \gamma = 0{,}5, \quad \text{step} = 15. \tag{16}$$

Biến thể tối ưu hóa thay thế bằng `ReduceLROnPlateau` (PyTorch [40]), giám sát validation loss $\mathcal{L}^{\text{val}}$ và chỉ áp dụng decay khi không thấy cải thiện trong `patience` epoch liên tiếp:

$$\eta_{k+1} = \begin{cases} \eta_k \cdot \text{factor} & \text{nếu } \mathcal{L}_k^{\text{val}} \geq \min_{j \leq k - \text{patience}} \mathcal{L}_j^{\text{val}} \\ \eta_k & \text{ngược lại.} \end{cases} \tag{17}$$

Tham số mặc định là `factor` $= 0{,}5$ và `patience` $= 5$.

4) Tương Tác Với Early Stopping: Cả scheduler plateau lẫn early stopping đều dùng validation loss làm tín hiệu giám sát. Để tránh đếm trùng patience, bộ đếm early stopping được reset mỗi lần scheduler kích hoạt decay. Điều này đảm bảo mô hình nhận ít nhất `patience×factor` epoch sau mỗi lần giảm learning rate trước khi quá trình huấn luyện được phép dừng lại.

F. Kết Quả Định Lượng và Diễn Giải

Bảng XI báo cáo kết quả đại diện một seed trên split test giữ lại.

Table XI: Baseline vs. Biến Thể Tối Ưu Hóa: Chỉ Số Test

Chỉ số	**Baseline**	**Tối ưu**	**Δ**
Precision	0,4767	0,5293	+0,0526
Recall	0,4767	0,5293	+0,0526
F-score	0,4767	0,5293	+0,0526
Temporal overlap	0,2347	0,3709	+0,1363

1) Cải Thiện F-Score (+5,3 điểm): Mức tăng +5,3 điểm phần trăm trong F-score phản ánh *phân biệt cấp frame cải thiện*: mô hình tối ưu chọn các frame nhất quán hơn với nhãn ground-truth đã nhị phân hóa. Động lực chính là Sửa đổi 1 (context fusion): bằng cách điều kiện hóa bộ chấm điểm trên vector ngữ cảnh toàn cục $\mathbf{c}$, mô hình học cách xếp hạng frame *tương đối với phân phối của chính clip* thay vì áp dụng ngưỡng cố định.

2) Cải Thiện Temporal Overlap (+13,6 điểm): Mức tăng +13,6 điểm phần trăm trong temporal overlap lớn hơn đáng kể so với mức tăng F-score và phản ánh *cải thiện cấu trúc bố cục tóm tắt* chứ không phải độ chính xác cấp frame. F-score cấp frame và temporal overlap có tương quan nhưng đo lường những thứ khác nhau: F-score thưởng cho việc chọn các frame quan trọng nhất cá lẻ, trong khi temporal overlap thưởng cho việc chọn frame từ cùng *vùng thời gian* với ground-truth.

Chiến lược chọn keyshot kết hợp (Sửa đổi 2) là động lực chính của mức tăng overlap. Pha 2 của thuật toán chọn lọc tường minh phân bổ ngân sách cho các bin thời gian chưa được đại diện, trực tiếp tăng xác suất rằng các đoạn được chọn giao với khoảng ground-truth phân bổ trên toàn timeline.

3) Đối Xứng Precision–Recall: Như thảo luận trong Phần VIII, giao thức nhị phân hóa top-k cân bằng số dự đoán dương và frame ground-truth dương, khiến Precision ≈ Recall trong chỉ số tổng thể. Cả hai đều bằng 0,5293 trong biến thể tối ưu hóa, xác nhận tính đối xứng này giữ tại điểm hoạt động mới.

4) Lưu Ý Đặc Thù Dataset: Cải thiện trong Bảng XI được báo cáo trên split test kết hợp SumMe/TVSum. Context fusion được kỳ vọng mang lại lợi ích cho TVSum (video dài giàu ngữ nghĩa) nhiều hơn SumMe (clip ngắn do người dùng tạo). Chiến lược chọn kết hợp có thể mang lại lợi ích nhiều hơn cho SumMe vì video ngắn có mật độ annotation đồng đều hơn.

G. Tóm Tắt Các Sửa Đổi

Table XII: Tóm Tắt Các Sửa Đổi Biến Thể Tối Ưu và Tác Động Chính

Sửa đổi	**Bottleneck chính giải quyết**	**Mức tăng chính kỳ vọng**
Context fusion (Eq. 10)	Chấm điểm chỉ cục bộ; không có tham chiếu toàn cục	F-score (phân biệt)
Chọn keyshot kết hợp (Eq. 11)	Tập trung thời gian của top-k	Temporal overlap (phủ)
Loss đa dạng phụ trợ (Eq. 14)	BCE thúc đẩy tập trung điểm	Overlap + Recall
Tăng λ_{wd} + ReduceLROnPlateau (Eq. 17)	Overfitting; decay LR sớm/muộn	Ổn định tổng quát hóa

Cả bốn sửa đổi nhắm vào *các khía cạnh khác nhau* của pipeline huấn luyện và inference và về cơ bản là độc lập về cơ chế: context fusion thay đổi *hàm chấm điểm*; chọn kết hợp thay đổi *chiến lược hậu xử lý*; loss đa dạng thay đổi *mục tiêu huấn luyện*; và thay đổi regularization/scheduling thay đổi *quỹ đạo tối ưu hóa*. Tính bổ sung của chúng là lý do chính khiến hệ thống chung vượt trội baseline trên cả bốn chỉ số được báo cáo đồng thời.

XI. Kết Luận

Báo cáo này trình bày một **Multimodal BiLSTM với Temporal Attention** sử dụng vector đặc trưng **2432 chiều**, được huấn luyện với học có giám sát tại tỷ lệ tóm tắt r=0,35. Các thực nghiệm ablation xác nhận mô hình đầy đủ đạt F-score TVSum 60,1%, cạnh tranh với các baseline dựa trên LSTM đã công bố, trong khi kết quả SumMe nêu bật độ nhạy với nhiễu nhánh âm thanh và ngân sách huấn luyện. Phân tích từng thành phần cho thấy tính hai chiều và Temporal Attention có lợi nhất cho nội dung giàu lời nói, trong khi đóng góp của nhánh âm thanh phụ thuộc mạnh vào chất lượng phiên âm và miền video.

Biến thể tối ưu hóa (Phần X) tiếp tục cải thiện F-score thêm +5,3 điểm và temporal overlap thêm +13,6 điểm so với baseline thông qua attention-context fusion, chọn keyshot kết hợp, loss phủ phụ trợ và regularization thích ứng.

Đánh giá qua **VideoIntel** chứng minh rằng **tìm kiếm ngữ nghĩa CLIP** trên tóm tắt chịu **suy giảm không đáng kể**, trong khi **chất lượng hỏi-đáp** phụ thuộc quyết định vào mật độ phiên âm và độ chính xác chủ đề—phản ánh tóm tắt video là **nén mất dữ liệu** và nhấn mạnh sự cần thiết của **kiểm định bài toán downstream** trước khi triển khai.

Appendix

Phụ lục này báo cáo một **thực nghiệm downstream** độc lập với việc huấn luyện BiLSTM trên SumMe/TVSum. Mục tiêu là đánh giá liệu các video do pipeline tóm tắt tạo ra có giữ lại đủ tín hiệu hành vi để huấn luyện một bộ phát hiện sự kiện đơn giản, so với video đầy đủ gốc. Bài toán được kiểm soát hoàn toàn: cùng loại đặc trưng, cùng classifier (random forest) và hai điều kiện huấn luyện chỉ khác nhau nguồn video (gốc vs. tóm tắt) và ánh xạ nhãn trục thời gian cho nhánh tóm tắt.

A. Động Cơ và Giả Thuyết

Điều kiện A huấn luyện trên video đầy đủ; **Điều kiện B** huấn luyện trên các tóm tắt tương ứng. Nếu các shot được giữ lại bao gồm vùng chuyển động cao liên quan đến sự kiện (va chạm, phanh gấp), Điều kiện B có thể đạt MAE thời gian thấp hơn hoặc tương đương nhờ chuỗi ngắn hơn và ít nhiễu hơn. Ngược lại, nếu bộ tóm tắt bỏ qua hoặc căn chỉnh sai các đoạn chứa sự kiện, Điều kiện B sẽ kém hơn.

Timestamp sự kiện cho Điều kiện B được thu bằng cách tích lũy thời lượng các đoạn được giữ lại theo thứ tự: nếu timestamp sự kiện ground-truth rơi trong một đoạn được giữ lại, nó được ánh xạ đến vị trí tương ứng trên timeline tóm tắt; nếu rơi vào vùng bị loại bỏ, mẫu đó có thể bị loại tùy theo quy ước annotation.

B. Định Nghĩa Bài Toán

Đầu vào. Một file video đơn; hệ thống lấy mẫu frame tại tốc độ cố định (ví dụ 4 fps) và tính vector đặc trưng thống kê cố định chiều mà không cần mạng deep nào ở giai đoạn này.

Đầu ra. (1) *Phân loại nhị phân*: có/không có sự kiện; (2) *Hồi quy thời gian*: timestamp sự kiện dự đoán $\hat{t}$ (giây), kẹp vào $[0, T]$ với T là thời lượng video.

Vector đặc trưng (mỗi video). Thời lượng, số frame lấy mẫu, trung bình và độ lệch chuẩn của độ lớn chuyển động frame-to-frame (tính trên frame grayscale downsampled qua OpenCV [47]), giá trị chuyển động đỉnh, thống kê độ sáng và vị trí thời gian của đỉnh chuyển động.

C. Dataset Thí Điểm

Table XIII: Phân Chia Dataset Thí Điểm Cho Phát Hiện Sự Kiện

Tập	Video
Huấn luyện	31
Kiểm chứng	8
Kiểm tra	6
Tổng	**45**

Toàn bộ nhãn được gán thủ công. **Hạn chế:** mỗi mẫu trong các split hiện tại đều mang nhãn sự kiện dương; do đó accuracy và F1 không cung cấp thông tin về phân biệt lớp âm. Chỉ số so sánh trung tâm là **temporal MAE** giữa hai điều kiện.

D. Quy Trình Huấn Luyện

- **Classifier:** random forest [46] với trọng số mẫu cân bằng lớp (300 cây).
- **Bộ hồi quy thời gian:** random forest riêng biệt (200 cây) chỉ huấn luyện trên mẫu lớp dương với timestamp hợp lệ.

Cả hai điều kiện chia sẻ siêu tham số và trích xuất đặc trưng giống nhau; chỉ nguồn video và nhãn được ánh xạ lại là khác nhau.

E. Tiêu Chí Đánh Giá

Accuracy và F1 được báo cáo cho đầy đủ nhưng không có tính phân biệt dưới phân phối nhãn toàn dương. Chỉ số chính là:

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N}\left|t_{\mathrm{gt},i} - \hat{t}_i\right| \quad \text{(giây)}. \tag{18}$$

F. Kết Quả

Table XIV: Kết Quả Phát Hiện Sự Kiện: Điều Kiện A (Gốc) vs. B (Tóm Tắt)

Tập	n	Acc / F1 (A / B)		MAE (s) (A / B)	
Huấn luyện	31	1,00 / 1,00	1,00 / 1,00	0,305	0,470
Kiểm chứng	8	1,00 / 1,00	1,00 / 1,00	1,622	0,292
Kiểm tra	6	1,00 / 1,00	1,00 / 1,00	0,549	1,269

Trên tập **kiểm chứng**, Điều kiện B đạt MAE thấp hơn; trên tập **kiểm tra**, Điều kiện A tốt hơn. Với chỉ 8 và 6 video, sự đảo ngược này không cho phép đưa ra kết luận thống kê chắc chắn. Kết quả gợi ý rằng các đặc trưng dựa trên tóm tắt có thể cạnh tranh khi các shot được giữ lại trùng với vùng sự kiện, nhưng quy mô nhỏ ngăn chặn sự tổng quát hóa.

G. Thảo Luận và Hướng Tương Lai

Video tóm tắt có thể tập trung thống kê chuyển động xung quanh các đoạn được giữ lại, có lợi cho hồi quy thời gian trên các split mà các đoạn đó trùng với vùng sự kiện, trong khi bị giảm hiệu suất trên các split mà bộ tóm tắt căn chỉnh sai vùng chọn. Tăng quy mô dataset, thêm mẫu lớp âm và áp dụng đặc trưng học sâu (I3D [34] hoặc TimeSformer [32]) là các hướng mở rộng tự nhiên hướng tới đánh giá nghiêm ngặt hơn.

Kết quả số cho tất cả các biến thể ablation—BiLSTM chỉ thị giác, BiLSTM đa phương thức đầy đủ, BiLSTM không có Temporal Attention và UniLSTM một chiều—được báo cáo trong Bảng III của Phần VIII. Tất cả các biến thể chia sẻ cùng giao thức đánh giá (split cố định, tỷ lệ tóm tắt cố định r=0,35, hậu xử lý giống nhau), cho phép gán sự khác biệt hiệu suất trực tiếp cho các lựa chọn kiến trúc riêng lẻ.

Đóng góp tăng dần của các thành phần kiến trúc thay đổi theo dataset. Trên **TVSum**, mô hình đa phương thức đầy đủ đạt F-score cao nhất (60,1%), xác nhận lợi ích của nhánh âm thanh-ngôn ngữ cho nội dung giàu lời nói (+0,4 điểm so với chỉ thị giác). Trên **SumMe**, các biến thể đơn giản hơn vượt trội mô hình đầy đủ trong lần chạy một seed này, nhất quán với độ nhạy ngân sách huấn luyện và nhiễu âm thanh thảo luận trong Phần VIII. Các phát hiện này phù hợp với tài liệu rộng hơn về các mô hình tóm tắt tuần tự [11], [15]: lợi ích kiến trúc phụ thuộc dataset và cần đánh giá nhiều seed để gán nhân quả chắc chắn.

Mở rộng sang các miền nội dung mới hoặc các bài toán downstream bổ sung (phân loại nội dung, captioning, retrieval trên video tóm tắt) nằm ngoài phạm vi báo cáo này nhưng được thúc đẩy bởi phân tích trong Phần X và Phụ lục A.

REFERENCES

[1] M. Gygli, H. Grabner, H. Riemenschneider, and L. Van Gool, "Creating summaries from user videos," in *ECCV*, vol. 8695, 2014, pp. 505–520.

[2] Y. Song, J. Vallmitjana, A. Stent, and A. Jaimes, "TVSum: Summarizing web videos using titles," in *CVPR*, 2015, pp. 5179–5187.

[3] E. Apostolidis, E. Adamantidou, A. I. Metsai, V. Mezaris, and I. Patras, "Video summarization using deep neural networks: A survey," *Proc. IEEE*, vol. 109, no. 11, pp. 1838–1863, 2021.

[4] H. B. Haq *et al.*, "Video summarization techniques: A review," *Math. Probl. Eng.*, vol. 2021, pp. 1–17, 2021.

[5] A. G. Money and H. Agius, "A survey on video summarization techniques," *Int. J. Comput. Appl.*, vol. 118, no. 11, pp. 25–31, 2015.

[6] P. Kadam *et al.*, "Recent challenges and opportunities in video summarization," *IEEE Access*, vol. 10, pp. 122762–122785, 2022.

[7] S. Hu *et al.*, "Video summarization based on feature fusion and data augmentation," *Computers*, vol. 12, no. 9, p. 186, 2023.

[8] V. Tiwari and C. Bhatnagar, "A survey of recent work on video summarization," *Multimed. Tools Appl.*, vol. 80, no. 18, pp. 27187–27221, 2021.

[9] P. Meena, H. Kumar, and S. K. Yadav, "A review on video summarization techniques," *Eng. Appl. Artif. Intell.*, vol. 118, p. 105667, 2023.

[10] Q. Yu *et al.*, "Deep learning for video summarization: Systematic review," *IEEE/CAA J. Autom. Sinica*, vol. 13, no. 1, pp. 21–42, Jan. 2026.

[11] K. Zhang, W.-L. Chao, F. Sha, and K. Grauman, "Video Summarization with Long Short-Term Memory," in *ECCV*, 2016.

[12] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[13] H. Ji, M. Xu, and J. Yang, "Video Summarization with Attention-Based Encoder-Decoder Networks," *arXiv:1708.09545*, 2017.

[14] Z. Ji *et al.*, "Video summarization with attention-based encoder–decoder networks," *IEEE Trans. Circuits Syst. Video Technol.*, vol. 30, no. 6, pp. 1709–1717, 2019.

[15] J. Fajtl *et al.*, "Summarizing Videos with Attention (VASNet)," in *ACCV*, 2018.

[16] A. Vaswani *et al.*, "Attention Is All You Need," in *NIPS*, 2017.

[17] L. Lan *et al.*, "FullTransNet: Full Transformer for Video Summarization," *arXiv:2501.00882*, 2025.

[18] E. Apostolidis *et al.*, "PGL-SUM: Pointer-Generator Network for Video Summarization," in *IEEE ISM*, 2021.

[19] S. A. Ghauri *et al.*, "MSVA: Multi-Stage Aggregated Transformer for Video Summarization," *arXiv:2104.11530*, 2021.

[20] Y. Zhu *et al.*, "MHSCNet: Multi-Head Self-Attention for Video Summarization," *arXiv:2204.08352*, 2022.

[21] B. Mahasseni, M. Lam, and S. Todorovic, "Unsupervised Video Summarization with Adversarial LSTM (SUM-GAN)," in *CVPR*, 2017.

[22] K. Zhang, K. Grauman, and F. Sha, "Retrospective Encoders for Video Summarization (Cycle-SUM)," in *AAAI*, 2019.

[23] E. Apostolidis *et al.*, "SUM-GAN-AED: Self-Attention GAN for Unsupervised Video Summarization," *arXiv:2307.08145*, 2023.

[24] W. Zhu *et al.*, "Relational Reasoning Over Spatial-Temporal Graphs for Video Summarization," *IEEE Trans. Image Process.*, vol. 31, pp. 3017–3031, 2022.

[25] T. Psallidas *et al.*, "Multimodal summarization of user-generated videos," *Appl. Sci.*, vol. 11, no. 11, p. 5260, 2021.

[26] B. He *et al.*, "Align and Attend: Multimodal Summarization with Dual Contrastive Losses," in *CVPR*, 2023.

[27] M. Narasimhan, A. Rohrbach, and T. Darrell, "CLIP-It! Language-Guided Video Summarization," in *NeurIPS*, vol. 34, pp. 13988–14000, 2021.

[28] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *CVPR*, 2016.

[29] A. Radford *et al.*, "Robust Speech Recognition via Large-Scale Weak Supervision (Whisper)," in *ICML*, 2023.

[30] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *EMNLP*, 2019.

[31] A. Radford *et al.*, "Learning Transferable Visual Models From Natural Language Supervision (CLIP)," in *ICML*, 2021.

[32] G. Bertasius, H. Wang, and L. Torresani, "Is Space-Time Attention All You Need for Video Understanding? (TimeSformer)," in *ICML*, 2021.

[33] Z. Liu *et al.*, "Video Swin Transformer," in *CVPR*, 2022.

[34] J. Carreira and A. Zisserman, "Quo Vadis, Action Recognition? (I3D)," in *CVPR*, 2017.

[35] J. Devlin *et al.*, "BERT: Pre-Training of Deep Bidirectional Transformers," in *NAACL*, 2019.

[36] W. Zhu *et al.*, "DSNet: A Flexible Detect-to-Summarize Network," *IEEE Trans. Image Process.*, 2021.

[37] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," in *ICLR*, 2015.

[38] I. Loshchilov and F. Hutter, "Decoupled Weight Decay Regularization (AdamW)," in *ICLR*, 2019.

[39] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

[40] PyTorch Developers, "`ReduceLROnPlateau`," https://pytorch.org/docs/stable/generated/torch.optim.lr_scheduler.ReduceLROnPlateau.html.

[41] M. Gygli, H. Grabner, and L. Van Gool, "Video Summarization by Learning Submodular Mixtures," in *CVPR*, 2015.

[42] H. Lin and J. Bilmes, "A Class of Submodular Functions for Document Summarization," in *NAACL*, 2011.

[43] R. Caruana, "Multitask Learning," *Machine Learning*, vol. 28, no. 1, pp. 41–75, 1997.

[44] FFmpeg Developers, *FFmpeg: A Complete Solution to Record, Convert and Stream Audio and Video*, https://ffmpeg.org.

[45] Ollama Developers, *Ollama: Run Large Language Models Locally*, https://ollama.com.

[46] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[47] G. Bradski, "The OpenCV Library," *Dr. Dobb's Journal of Software Tools*, 2000.

[48] B. Zhao, X. Li, and X. Lu, "HSA-RNN: Hierarchical Structure-Adaptive RNN for Video Summarization," in *CVPR*, 2018.

[49] X. Shang *et al.*, "Multimodal Video Summarization via Time-Aware Transformers," in *ACM MM*, 2021, pp. 1756–1765.

[50] H. Khan *et al.*, "Deep multi-scale pyramidal features network for video summarization," *Expert Syst. Appl.*, vol. 237, p. 121288, 2024.

[51] B. Zhao, X. Li, and X. Lu, "HSA-RNN: Hierarchical Structure-Adaptive RNN for Video Summarization," in *CVPR*, 2018.

[52] Y. Jung, D. Cho, D. Kim, S. Woo, and I.-S. Kweon, "Discriminative Feature Learning for Unsupervised Video Summarization," in *Proc. AAAI Conf. Artif. Intell.*, vol. 33, pp. 8537–8544, 2019.

[53] K. Zhou, Y. Qiao, and T. Xiang, "Deep reinforcement learning for unsupervised video summarization with diversity-representativeness reward," in *Proc. AAAI Conf. Artif. Intell.*, vol. 32, 2018.

[54] G. Wang, X. Wu, and J. Yan, "Progressive reinforcement learning for video summarization," *Information Sciences*, vol. 655, p. 119888, 2024.

[55] T. Liu *et al.*, "Video Summarization through Reinforcement Learning with a 3D Spatio-Temporal U-Net," *IEEE Trans. Image Process.*, vol. 31, 2022.

[56] X. Shang, Z. Yuan, A. Wang, and C. Wang, "Multimodal Video Summarization via Time-Aware Transformers," in *Proc. ACM Int. Conf. Multimedia (ACM MM)*, 2021, pp. 1756–1765.

[57] A. Miech *et al.*, "HowTo100M: Learning a Text-Video Embedding by Watching Hundred Million Narrated Video Clips," in *ICCV*, 2019.

[58] A. Dosovitskiy *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (ViT)," in *ICLR*, 2021.

[59] R. Zhong *et al.*, "Semantic Representation and Attention Alignment for Graph Information Bottleneck in Video Summarization," *IEEE Trans. Image Process.*, 2023.

[60] H. Khan, T. Hussain, S. U. Khan, Z. A. Khan, and S. W. Baik, "Deep multi-scale pyramidal features network for supervised video summarization," *Expert Syst. Appl.*, vol. 237, p. 121288, 2024.